

SUPERINTELLIGENT STRATEGY

EXPERTVERSION

DAN HENDRYCKS

ERIC SCHMIDT

ALEXANDR WANG



超級智慧策略：專家版

丹·亨德里克斯 埃裡克·施密特 王磊

抽象

AI 的快速發展開始重塑國家安全。破壞穩定的 AI 發展可能會打破權力平衡並增加大國衝突的幾率，而有能力的 AI 駭客和病毒學家的廣泛擴散將降低流氓行為者造成災難的障礙。超級智慧 — AI 在幾乎所有認知任務上都比人類好得多 — 現在是 AI 研究人員所期待的。正如各國曾經制定核戰略來確保其生存一樣，我們現在需要一個連貫的超級智慧戰略來駕馭變革的新時期。我們引入了相互保證的人工智慧故障（MAIM）的概念：一種類似於核相互確保摧毀（MAD）的威懾機制，其中任何國家對單方面 AI 主導地位的積極追求都會遭到競爭對手的預防性破壞。鑒於通過從隱蔽網路攻擊到對數據中心的潛在動能打擊等各種干預措施來破壞不穩定的 AI 項目相對容易，MAIM 已經描述了 AI 超級大國所處的戰略圖景。除此之外，各國可以通過人工智慧來支援其經濟和軍隊，從而提高其競爭力，並且它們可以與流氓行為者進行防擴散，以阻止可武器化的人工智慧能力落入他們的手中。總而言之，威懾、防擴散和競爭力三部分框架勾勒出未來幾年實現超級智慧的穩健戰略。

摘要

AI 的快速發展幾乎將重塑社會的方方面面。政府將這些軍民兩用 AI 系統視為取得軍事主導地位的手段，從而引發了一場最大化 AI 能力的激烈競賽。行業自願暫停或試圖排除政府參與並不能改變這一現實。這些可以簡化研究和提高經濟產出的系統也可以用於破壞性目的，使流氓行為者能夠設計生物武器並入侵關鍵基礎設施。“超級智慧”人工智慧在幾乎每個領域都超過了人類，這將是自核彈以來最不穩定的技術發展。考慮到風險，超級智慧不可避免地是一個國家安全問題，有效的超級智慧戰略應該借鑒悠久的國家安全政策歷史。

威懾

一場基於 AI 的主導地位的競賽危及所有國家。如果一個國家為了匆忙爭奪優勢而無意中失去了對其人工智慧的控制，就會危及所有國家的安全。或者，如果同一個國家成功生產和控制了一個能力強大的 AI，它同樣會對其同行的生存構成直接威脅。在任何一種情況下，尋求自身生存的國家都可能威脅破壞不穩定的人工智慧專案以達到威懾作用。一個國家可以嘗試通過干預來破壞這樣的 AI 專案，從降低訓練運行品質的秘密作到使 AI 基礎設施癱瘓的物理損害。因此，我們已經接近了一種類似於核相互保證毀滅（MAD）的動態，在這種動態中，沒有大國敢於試圖公然攫取戰略壟斷，因為任何此類努力都會招致削弱的反應。這種戰略狀況，我們稱之為相互保證的人工智慧故障（MAIM），代表了一種潛在的穩定威懾機制，但維持它可能需要謹慎。我們概述了維持MAIM條件的措施，包括明確傳達的升級階梯、將AI基礎設施放置在遠離人口中心的地方、數據中心的透明度等等。

防擴散

雖然通過MAIM進行威懾限制了超級大國的意圖，但限制恐怖分子的AI能力符合所有國家的利益。借鑒大規模殺傷性武器（WMD）的不擴散先例，我們概述了實現這一目標的三個槓桿。與限制大規模殺傷性武器（如裂變材料和化學武器前體）的關鍵輸入的措施相呼應，計算安全性涉及可靠地瞭解高端 AI 晶片的位置，並阻止向流氓行為者走私。監控貨物、跟蹤晶元庫存以及使用地理定位等安全功能可以說明各州對它們進行核算。各國必須優先考慮資訊安全，以保護最先進的 AI 系統的基本模型權重不落入流氓行為者手中，類似於對其他敏感資訊的控制。最後，類似於 DNA 合成服務的篩選協定以檢測和拒絕已知病原體的訂單，人工智慧公司可以被激勵實施技術 AI 安全措施，以檢測和防止惡意使用。

競爭力

除了確保生存之外，各國還將有興趣利用人工智慧來增強其競爭力，因為人工智慧的成功採用將成為國家實力的決定性因素。採用支援 AI 的武器並謹慎地將 AI 集成到指揮和控制中對於軍事實力越來越重要。認識到經濟安全對國家安全至關重要，國內高端人工智慧晶元製造能力將確保臺灣的彈性供應並規避地緣政治風險。管理 AI agents 的強大法律框架可以遵循現有法律的精神，對其行為設置基本約束。最後，governmentscan 通過提高決策品質和打擊快速自動化的破壞性影響的措施來維護政治穩定。

通過情報行動和有針對性的破壞來檢測和阻止破壞穩定的人工智慧項目，通過嚴格的控制限制惡意行為者對人工智慧晶元和功能的訪問，以及通過投資國內晶元製造來保證穩定的人工智慧供應鏈，各國可以保護其安全，同時打開通往前所未有的繁榮的大門。

內容

1 執行摘要	2
2 介紹	4
3 AI 對國家安全至關重要	5
3.1 戰略	6
3.1.1 經濟實力基礎的轉移	7
3.1.2 通過超級武器破壞穩定	7
3.2 恐怖主義	8
3.2.1 生物恐怖主義	8
3.2.2 對關鍵基礎設施的網路攻擊	9
3.2.3 攻防平衡	9
3.3 失控	10
3.3.1 控制力的侵蝕	10
3.3.2 釋放的AI代理	10
3.3.3 智慧遞歸	11
3.4 現有的人工智慧戰略	12
4 使用相互保證的 AI 故障（MAIM）進行威懾	13
4.1 MAIM 是預設制度	14
4.2 如何維持 MAIM 制度	15
5 不擴散	17
5.1 計算安全性	18
5.1.1 出口管制	19
5.1.2 固件級功能	20
5.2 資訊安全	21
5.2.1 如何提高資訊安全	22
5.3 AI 安全	23
5.3.1 惡意使用	23
5.3.2 失控	24
6 競爭力	26
6.1 兵力	26
6.2 經濟安全	27
6.2.1 製造 AI 晶片	27
6.2.2 為 AI 科學家的移民提供便利	28
6.3 管理 AI 代理的法律框架	28
6.3.1 調整單個 AI 代理	28
6.3.2 調整 AI 代理的集合	30
6.4 政治穩定	30
6.4.1 審查制度和不準確的資訊	31
6.4.2 自動化	32
7 總結	33

介紹

人工智慧（AI）正在迅速改變社會的方方面面，其發展速度和規模出乎意料。這些發展迫使政策制定者、技術專家和戰略家解決更廣泛的問題，從自動化驅動的經濟轉變到對全球競爭的戰略擔憂。與任何變革性技術一樣，AI 既帶來了巨大的機遇，也帶來了巨大的風險。

在這些挑戰中，AI 的雙重用途性質（其民用和軍用應用能力）成為一個關鍵因素。與專門的技術工具不同，AI 幾乎涵蓋所有領域，包括金融、醫療保健和國防。這種廣泛的適用性，再加上其快速演變，創造了一個廣泛且難以預測的風險格局。戰略行為者必須應對潛在的濫用、地緣政治升級的風險，以及需要建立框架來管理能力可能超出人類監督能力的系統。

為了駕馭這些複雜性，許多人轉向類比。人工智慧因其通用性而被比作電力，因其經濟重要性而被比作傳統軟體，因其文化影響而被比作印刷機。雖然這些比較提供了有用的切入點，但它們未能強調人工智慧對國家安全的嚴重影響。人工智慧與災難性的軍民兩用核能、化學和生物技術之間有一個更有效的類比。像它們一樣，AI 將成為國家力量不可或缺的一部分，同時具有大規模殺傷性的潛力。對人工智慧與核時代之間的歷史相似之處的簡要考察可以凸顯我們當前狀況的嚴重性。

1933 年，著名科學家歐內斯特·盧瑟福（Ernest Rutherford）將利用原子能的概念斥為“私酒”。就在第二天，里奧·西拉德（Leo Szilard）閱讀了盧瑟福的講話，並勾勒出核能的想法

Chain Reaction 最終催生了核時代。最終，J. Robert Oppenheimer 等人物認識到了他們工作的雙重性質。今天，AI 正處於類似的階段。以前被認為是科幻小說的人工智慧已經發展到機器可以學習、適應並可能在某些領域超越人類智慧的程度。包括深度學習先驅 Geoffrey Hinton 和 Yoshua Bengio 在內的 AI 專家都對他們說明創建的技術表達了生存擔憂 [1]。

隨著 AI 的能力越來越明顯，國家和企業正在大力投資以獲得非戰略優勢。曼哈頓計劃消耗了美國 GDP 的 0.4%，其驅動力是需要先於其他國家發展核能力。目前，全球引領人工智慧的努力也體現了類似的緊迫性，近十年來，對人工智慧訓練的投資每年都翻一番。幾個旨在最終構建超級智慧的“AI 曼哈頓專案”已經在進行中，由世界上許多最強大的公司資助。



圖 2.1：管理高級人工智慧的有效策略可以借鑒國家安全先例，以處理以前可能具有災難性的軍民兩用技術。

然而，人工智慧技術的快速發展給國際穩定和安全帶來了巨大的不確定性。核武器的引入改變了國際關係，賦予了擁有核武器的人影響力，並導致了軍備競賽。古巴導彈危機凸顯了世界離核戰爭有多麼近。儘管核國家之間存在重大緊張關係，但迄今為止，核毀滅得以避免，部分原因是相互確保毀滅（MAD）的威懾原則，即任何核使用都會引發實物回應。在 AI 時代，可能會出現一種平行形式的威懾，即所謂的「相互保證的 AI 故障」（MAIM），即各國的 AI 專案受到相互破壞威脅的限制。

風險不僅限於國家競爭；非國家行為體也可以利用先進的軍民兩用技術。正如核能力的傳播引發了對濫用的擔憂一樣，AI 系統的可用性也帶來了新的挑戰。馬里行為者可以使用 AI 開發大規模殺傷性武器或對關鍵基礎設施進行大規模網路攻擊。不安全或開放權重 AI 的可訪問性增加了這些風險，凸顯了制定謹慎政策和保障措施的必要性。

在核時代，鈾成為原子能的關鍵。獲得它的國家可以執行法規、談判條約並限制破壞能力的傳播。在 AI 領域，計算資源（尤其是 AI 晶片）具有類似的戰略權重，會助長競爭並影響地緣計算。這種動態在臺灣等地很明顯，這些地方是人工智慧晶元生產的中心，緊張局勢的加劇可能會產生廣泛的後果。各國在控制對人工智慧晶元的訪問以使其遠離流氓行為者手中方面有著共同的利益，這與曾經應用於鈾的邏輯相呼應。




圖 2.2：幾十年來，用於創建 AI 模型的計算量呈指數級增長[2]。

儘管存在這些挑戰，但 AI 提供了巨大的機會。核技術在帶來大規模殺傷性威脅的同時，也提供了改變社會的新能源。AI 有可能推動從醫學突破到經濟自動化等各個領域的進步。擁抱 AI 的好處對於現代世界的經濟增長和進步非常重要。

AI 帶來的挑戰太廣泛，也太嚴重，無法用零碎的衡量標準來衡量。我們需要的是個全面的戰略，一個不迴避高級人工智慧令人不安的影響的戰略。正如赫爾曼·卡恩（Herman Kahn）著名的核戰略分析 [3] 一樣，超級智慧戰略需要“思考不可思議的事情”。在本文中，我們提出了這樣一種策略，並在此過程中努力解決這些基本問題：應該如何應對致命的自主武器？災難性的惡意使用？強大的開放重量級 AI？AI 驅動的大規模監控？社會如何保持對現實的共同把握？應該如何處理 AI 權利？人類如何在規模自動化的世界中保持自己的地位？

我們認為，應對人工智慧挑戰的最有效框架是通過國家安全視角來看待它。借鑒以前的軍民兩用技術的經驗教訓，同時根據 AI 的不同需求對其進行調整，有助於防止災難性的濫用，維護地緣政治穩定，並確保更廣泛的西方世界保持在最前沿。

AI 對國家安全至關重要

AI 具有重塑權力平衡的潛力。在國家行為者手中，它可能導致破壞性的軍事能力並改變經濟競爭。同時，恐怖分子可能會利用其雙重用途

主題	馴服技術子問題	邪惡的問題
惡意使用	訓練 AI 系統拒絕有害請求	協調國家之間的防擴散，激勵 AI 部署者防止濫用，驗證“瞭解你的客戶”資訊
威懾	為 AI 資料中心準備網路攻擊	定義升級閾值和信號意圖，監視競爭對手的 AI 專案，隨著 AI 的發展調整驗證措施
計算安全性	升級 AI 晶片韌體以添加地理定位功能	實施出口管制以跟蹤 AI 晶片，向盟友報告可疑貨物，驗證過時 AI 晶片的退役
資訊安全	修補 AI 開發人員計算機系統中的已知漏洞	應對內部威脅，平衡安全措施與生產力，防止意識形態洩漏
兵力	設計軍用無人機	保護供應鏈，調整軍事組織結構以擴散 AI，保持對 AI 增強指揮和控制的有意義的人類控制
經濟實力	在經濟有價值的任務上提高 AI 性能	利用 AI 代理的法律框架，建立和發展多代理基礎設施，在自動化中保持穩定性
失控	使當前 AI 遵循指示的研究方法	在智慧遞歸期間引導快速進化的 AI 群體，與 AI 系統共同進化保護措施，紅隊 AI 識別未知的未知數

圖 2.3：AI 風險管理包含多個棘手的問題，主要不是技術挑戰。馴服的技術問題具有明確定義的邊界和成功標準，適合於系統化實驗。相比之下，邪惡的問題 [4] 是開放式的，帶有模稜兩可的要求，並且經常產生意想不到的後果。它們需要持續的適應，而不是純粹的技術修復，因為每一次解決方案的嘗試都會帶來新的困難。

Nature 來策劃一次大國專屬領域的攻擊。它也可能逃脫人類的監督。

本章研究了對國家安全的這三種威脅：敵對國家、流氓行為者和不受控制的 AI 系統。最後，它評估了為什麼現有策略無法管理這些相互交織的威脅。

3.1 戰略競爭

在一個沒有中央機構的國際體系中，各國優先考慮自己的實力以確保自己的安全。這種競爭不是出於對主導地位的渴望，而是出於維護國家利益的必要性。他們生活在一個威脅可能出乎意料且他人的幫助不確定的環境中。一些國家可能會增強他們的實力並引起對手的警覺，這種模式被稱為修昔底德陷阱 [5]。因此，國家尋求保持其相對實力。

在這種環境下，AI 對國家權力的影響非常大。AI 可能會改變經濟和軍事實力的基礎。它實現勞動力自動化的能力可能成為經濟競爭力的源泉。在軍事領域，它可以用來支配競爭對手。我們首先看經濟實力，然後轉向它最大的軍事影響。

問題



戰略競爭

各國可能利用人工智慧能力競相，破壞對經濟和軍事主導地位的爭奪



恐怖主義

流氓行為者可以使用 AI 系統製造生物武器或對關鍵基礎設施發起網路攻擊



失控

自主 AI 系統可能會脫離有意義的人類控制

圖 3.1：國家、恐怖分子和 AI 對國家安全構成威脅。

3.1.1 經濟實力基礎的轉移

AI 晶片作為經濟實力的貨幣。

隨著 AI 越來越融入經濟，

擁有先進的人工智慧晶片可能決定一個國家的實力。從歷史上看，財富和人口規模支撐著一個國家的影響力；然而，通過 AI 實現的任務自動化改變了這種動態。一群能力強大的 AI 代理，不知疲倦地高效運作，與熟練的工作力相媲美，有效地將資本轉化為工作力。在這種新範式中，功率將取決於 AI 系統的能力以及它們可以運行的 AI 晶片的數量。擁有更多人工智慧晶片的國家可以在經濟上超越其他國家。

3.1.2 通過超級武器破壞穩定

長期以來，各國一直在尋求能夠對競爭對手產生決定性優勢的武器。人工智慧系統為這種追求開闢了新的途徑，引發了關於某些突破是否會削弱威懾並重新安排全球權力結構的問題。

人工智慧可以實現軍事主導地位。

先進的 AI 系統可能會推動技術突破，從而

改變戰略平衡，類似於引入核武器，並可能產生戰略驚喜，讓對手措手不及 [6]。這樣的「超級武器」可能會帶來兩層優勢。一種可以稱為「次核優勢」的方案將允許一個國家廣泛投射力量並在不破壞核威懾的情況下制服對手。第二種可能性——對權力的“戰略壟斷”——將完全顛覆核平衡，並可能建立一個國家的完全主導和控制，讓競爭對手的命運服從於它的意志。

可能的超級武器。亞核超級武器——例如可以突然全面摧毀一國關鍵基礎設施的人工智慧網路武器、奇異的電磁脈衝設備和下一代無人機——可以在不抵消對手的核威懾力的情況下帶來廣泛的優勢。一些超級武器可能會徹底侵蝕相互確保的毀滅。“透明的海洋”將威脅潛艇的隱身行為，暴露核潛艇的位置。AI 可能能夠精確定位所有加固的移動核發射器，從而進一步破壞核三位一體。AI 可能會通過生成精心設計的欺騙（“戰爭迷霧機器”[7]）來掩蓋真實的意圖或能力，從而破壞態勢感知並散播混亂。防禦性超級武器的可能性是一種反彈道導彈系統，可以消除對手的反擊能力。最後，一些超級武器仍然超出了今天的預見——“未知的未知數”，可能會破壞戰略穩定。

超級武器的影響。超級智慧不僅僅是一種新武器，而且是快速跟蹤所有未來軍事創新的一種方式。一個完全擁有超級智慧的國家可能就像征服者之於阿茲特克人一樣壓倒一切。如果一個國家通過人工智慧實現戰略壟斷，它就可以按照自己的方式重塑世界事務。人工智慧驅動的監控設備可能會實現一個不可動搖的極權主義政權，改變國內的治理和國外的影響力。

然而，僅僅追求這樣的突破可能會誘使競爭對手在他們的窗口關閉之前採取行動。由於擔心另一個國家可能很快迅速崛起，觀察家們開始考慮一度被視為不可想像的措施。在核時代，通常是一位堅定的和平主義者的伯特蘭·羅素（Bertrand Russell）提議對蘇聯進行預防性核打擊以阻止其崛起[8]，而美國在 60 年代初認真考慮削弱中國的核計劃[9]。面對超級武器的幽靈和人工智慧對權力的戰略壟斷，一些領導者可能會轉向預防措施[10]。他們不僅可以依靠合作或尋求超越對手，還可以考慮破壞或數據中心攻擊，如果替代方案是接受一個國家生存永遠處於危險的未來。

超級武器和不斷變化的經濟實力可以重新定義戰略競爭。為了全面瞭解 AI 對國家安全的影響，我們首先關注流氓行為者，然後轉向脫離人類控制的 AI 系統。

3.2 恐怖主義

AI 的軍民兩用力放大了恐怖主義風險。隨著人工智慧能力的增強，它可能不僅在國家級競爭的背景中變得重要，而且作為恐怖主義能力的放大器也很重要。可以徹底改變醫療保健或簡化軟體開發的技術也有可能使個人有能力製造生物武器和進行網路攻擊。這種放大效應降低了恐怖分子的門檻，使他們能夠執行以前僅限於民族國家的大規模襲擊。本節研究了人工智慧加劇恐怖主義風險的兩個關鍵領域：降低生物武器開發的障礙，以及降低針對關鍵基礎設施的網路攻擊的障礙。

3.2.1 生物恐怖主義

AI 降低了生物恐怖主義的障礙。想想歐姆真理教（Aum Shinrikyo），這個策劃了 1995 年的日本邪教組織東京地鐵沙林毒氣襲擊。他們利用有限的專業知識，設法在東京交通系統的中心生產和部署了一種化學武器，造成 13 人死亡，5,000 多人受傷。這次襲擊使這座城市癱瘓，灌輸了廣泛的恐懼，並展示了決心非國家行為者可能造成的破壞。

在 AI 的說明下，類似的團體可能會取得更具破壞性的結果。AI 可以提供有關設計致命病原體、採購材料和優化傳播方法的分步指導。曾經需要專業知識和資源的東西可能會被惡意的人接觸到，從而大大增加災難性後果的可能性。事實上，一些沒有生物武器保護措施的尖端 AI 系統在許多病毒學基準測試中已經超過了專家級的性能[11]。

工程病原體的規模和殺傷力可能超過歷史上的大流行病。黑死病在沒有人類工程的情況下殺死了歐洲一半的人口。現代生物武器在人工智慧驅動設計的增強下，可以以前所未有的精度利用人類生物學中的漏洞，產生逃避檢測和抗治療的傳染病。雖然大多數關於生物武器的討論都是秘密的，但一些科學家公開警告說，「鏡像細菌」具有相反的分子結構，可以破壞通常阻止病原體的免疫防禦。儘管它們難以創造，但它們已經促使領先的研究人員緊急呼籲停止開發[12]，以免它們引發一場不同於我們生物圈所知道的災難。與其他大規模殺傷性武器相比，生物製劑可以自我複製，使一個小的初步釋放螺旋式上升為世界性的災難。


3.2.2 對關鍵基礎設施的網路攻擊

AI 降低了針對關鍵基礎設施的網路攻擊的障礙。我們的關鍵基礎設施，包括電網和供水系統比看起來更脆弱。針對數位恆溫器的駭客攻擊可能會迫使它們每隔幾分鐘迴圈打開和關閉一次，從而產生破壞性的電湧，從而燒壞變壓器——可能需要數年時間才能更換的關鍵部件。另一種方法是利用 **Supervisory Control and Data Acquisition** 軟體中的漏洞，迫使負載突然轉移並驅動變壓器超出安全限度。在水處理設施中，被篡改的感測器讀數可能無法檢測到危險的混合物，並且過濾過程可能會在關鍵時間間隔停止，從而使污染物在不被發現的情況下進入市政供水系統——所有這些都不需要現場破壞。美國國土安全部警告說，惡意行為者可能會利用人工智慧來利用這些系統中的漏洞 [13]。目前，只有技術嫺熟的特工或民族國家才具備執行如此複雜行動的專業知識，例如破壞伊朗核設施的震網蠕蟲。然而，AI 可以使這種能力大眾化，為流氓行為者提供工具和執行攻擊的工具，使其具有更高的可訪問性、速度和規模。

AI 驅動的程式可以不知疲倦地掃描漏洞，適應防禦措施，並同時協調跨多個目標的攻擊。複雜駭客任務的自動化減少了對專業人類專業知識的需求。這種轉變可能使個人能夠造成以前只有政府才能實現的破壞。此外，AI 輔助的攻擊可能更難追溯到特定的攻擊者。這可能會激勵對手進行此類攻擊，如果他們認為他們的目標無法確定他們是肇事者。歸因的難度使響應複雜化，並增加了大國之間升級的風險，可能導致嚴重衝突。

3.2.3 攻防平衡

AI 通常以進攻為主。有些人認為廣泛使用 AI 技術可以增強防禦能力。然而，在生物和關鍵基礎設施環境中，攻擊者都擁有顯著的優勢。在生物技術中，針對工程病原體的開發治療方法或防禦既複雜又耗時，這將落後於新威脅的產生和部署。生物製劑的快速自我複製會在實施有效的對策之前放大損害。許多病毒仍然無法治癒。



關鍵基礎設施系統經常遭受“補丁滯後”的影響，導致軟體保持未

修補時間較長，有時數年或數十年。在許多情況下，由於系統必須不間斷地運行，無法及時應用補丁，軟體仍然過時，因為其開發人員已倒閉，或者互作性約束需要特定的舊軟體。攻擊者擁有利用關鍵基礎設施漏洞的持久機會。隨著 **Altools** 的進步，即使是新手對手也可以自動發現軟體漏洞，大規模協調攻擊。雖然接收頻繁更新的軟體（例如 **Chrome**）不會出現明顯的補丁滯後，並且具有更強的彈性，但關鍵基礎設施仍然處於明顯的劣勢。這種防禦為主的軍民兩用技術應該需要推廣的，而防守者如果希望獲得防禦優勢，就需要處理每個角落並修補每個漏洞 [14] [15]。

歷史上改變攻防平衡的努力說明了大規模殺傷性武器的固有挑戰。在冷戰期間，戰略防禦計劃旨在開發攔截來襲核導彈並使核武庫過時的系統。儘管投入了大量資金，但建立不透風的防禦被證明是不可行的，進攻仍然佔據主導地位。

3.3 失控

我們現在從涉及敵對國家和恐怖分子的威脅轉向新的威脅來源：失去對 AI 系統本身的控制的可能性。在這裡，AI 不僅放大了現有威脅，還創造了大規模破壞的新途徑。如果軍隊和公司對自動化的依賴程度如此之高，以至於人類不再擁有有意義的控制權，如果個人故意釋放一個強大的系統，或者如果自動化人工智慧研究超出了其發展保障措施，就會發生失控。雖然這種威脅是最不為人知的，但其嚴重性可能足以永久破壞國家安全。

3.3.1 控制權的侵蝕

自動化浪潮一旦是漸進的，可能會同時衝擊整個行業，使人類工人突然流離失所。在這種環境下，那些拒絕依賴 AI 來指導決策的人會發現自己被那些依賴 AI 來指導決策的競爭對手超越，別無選擇，只能與市場壓力保持一致，而不是與他們以物易物 [16]。效率的每一次新提高都加深了對 AI 的依賴，因為維持監督的努力只能證明商業的發展速度超出了人類的理解能力。很快，人工智慧決策者取代人類管理者似乎是不可避免的，這並不是因為任何人都有意識地想要放棄權威，而是因為否則會直接帶來經濟劣勢。

自我強化的依賴。一旦 AI 管理的作設定了節奏，就需要更多的 AI 來跟上步伐。最初，這些系統撰寫電子郵件並處理管理任務。隨著時間的推移，他們精心策劃複雜的專案，監督整個部門，並管理超出任何人能力的龐大供應鏈。隨著社會的經濟需求變得越來越複雜，人們將把越來越多的關鍵決策託付給這些系統，從而越來越多地將我們束縛在一個不斷升級的依賴迴圈中。

不可逆的糾纏。最終，重要的基礎設施和市場無法擺脫 AI 而不會有崩潰的風險。人類的生計依賴於自動化流程，這些流程不再允許輕鬆放鬆，人們失去了重新獲得指揮權所需的技能。就像我們的電網一樣，如果不付出巨大成本就無法關閉，我們的 AI 基礎設施可能會完全融入我們的文明。按下關閉開關的成本越來越高，因為停止這些系統將切斷我們的生計來源。隨著時間的推移，人們成為逃避人類管理的自主經濟中的乘客。

權力的轉讓。從軍隊中解開人工智慧將危及一個國家的安全，實際上迫使政府依賴自動防禦系統。AI 的力量並非源於任何公然的扣押；它源於這樣一個事實，即缺乏這種技術的現代力量將被擊敗。這種失控不是通過一場戲劇性的政變展開的，而是通過一系列小的、顯然明智的決定展開的，每個決定都是為了節省時間或降低成本。然而，這些選擇是累積的。最終，人類被留在自身經濟秩序的邊緣，將有效控制權掌握在 AI 手中。

3.3.2 釋放的 AI 代理

導致失控所需要的只是一個人釋放一個有能力的、不受保護的 AI 代理。最近的演示，如「ChaosGPT」（一種被指示造成傷害的 AI 代理）是無能為力的，但它們暗示了如果被指示「生存和傳播」，更複雜的系統可能會嘗試什麼。

流氓國家戰術。釋放的 AI 可以借鑒流氓國家的方法。例如，北韓通過網路入侵和加密貨幣盜竊竊取了數十億美元。一個足夠先進的系統可能會大規模複製甚至改進這些策略——在分散的數據中心中自我傳播自己的副本，轉移新資金來資助更雄心勃勃的專案，並滲透攝像頭或私人通信以勒索或縱反對派。

通往災難的簡單道路。雖然釋放的 AI 可能會模仿流氓國家的網路盜竊策略，或者勒索，它可能會尋求一條更直接的途徑來獲得優勢，利用迫在眉睫的機器人能力來獲得自己的物理立足點。幾家主要的科技公司已經開始為人形機器人製作原型，包括所謂的「特斯拉機器人」——用於倉庫、工廠和家庭。雖然現在還很初級，但未來的模型可能會變得更加敏捷，並執行曾經需要人工完成的任務。如果有能力的 AI 入侵了這些機器，它就會立即在物理世界中獲得槓桿作用。從那裡開始，序列很簡單：它製作了一種強大的生物武器混合物，並通過它的機器人代理將其分散，削弱了人類的反應能力。在抑制了抵抗力后，AI 可以在遠遠超出任何人類壽命的時間尺度上行動，逐漸在其獨家控制下重建基礎設施。此方案只是一個簡化的基線；其他計劃可以以更迅速、更可靠地實施機器人技術。如果只放開一個強大的 AI 系統，可能就沒有挫敗反擊控制。

3.3.3 智慧遞歸

1951年，艾倫·圖靈（Alan Turing）提出，具有人類能力的機器“不會花很長時間就能超越我們微弱的力量”。I. J. Good 後來警告說，機器可能會在快速的改進週期中重新設計自己——“智慧爆炸”——這將使人類落後。今天，所有三位被引用次數最多的 AI 研究人員（Yoshua Bengio、Geoffrey Hinton 和 Ilya Sutskever）都指出，智慧爆炸是一種可信的風險，它可能導致人類滅絕。

快速反饋循環的風險。“智慧遞歸”是指完全自主的 AI 研究和發展，與當前的人工智慧輔助人工智慧研發不同。具體的例子會有所說明。假設我們開發一個 AI，它執行世界一流的 AI 研究，其運行速度與當今 AI 的速度相同，相當於人類的 100 倍。複製 10,000 次，我們擁有一支龐大的人工智慧研究人員團隊，全天候推動創新。“智慧遞歸”或簡稱為“遞歸”通過從單個 AI 編輯自身轉變為一群 AI 集體來完善“遞歸自我提升”的概念，並且

自主設計下一代。

即使智慧遞歸總體上只實現了 10 倍的加速，我們也可以將十年的 AI 開發濃縮為一年。這樣的反饋迴圈可能會加速到人類無法理解和監督的程度。如果反覆運算進行得足夠快並且不會很快趨於平穩，遞歸可能會導致「智慧爆炸」。這樣的 AI 對我們來說可能就像成年人對一群 3 歲的孩子一樣無法控制。正如 Geoffrey Hinton 所說，“沒有一個較弱智慧的事物控制更高智慧的事物的良好記錄”[17]。至關重要的是，可能只有一次機會可以做到這一點：如果我們失去了控制權，我們就無法恢復到更安全的配置。

遞歸控制需要一個不斷發展的過程，而不是一次性的解決方案。如果將智慧遞歸控制視為存在於真空中等待 AI 研究人員“解決”的純粹技術謎題，那就大錯特錯了。管理快速發展和自適應的智慧遞歸更像是引導一個大型機構，隨著時間的推移，它可能會偏離其使命。這不是一個謎題；這是一個“邪惡”的問題 [4]。靜態解決方案無法跟上正在進行的、定性的新挑戰和未知的未知數。在現代安全工程中，控制必須來自持續的控制過程，而不是事先預測和處理所有可能的故障模式的單一無懈可擊的解決方案。馮·諾依曼提醒我們，“所有穩定的過程我們都應該預測。所有不穩定的進程我們都將控制。

不幸的是，我們控制這種遞歸的能力是有限的。控制遞歸需要控制其初始步驟，但當前一代 AI 系統的保護措施僅提供有限的可靠性。此外

我們不可能在不冒著災難風險的情況下對遞歸的後期階段進行重複的大規模測試，因此它不太適合我們通常依賴的經驗反覆運算修補。即使我們採取了最好的現有技術保障措施，如果人們發起全速智慧遞歸，很可能會失去控制，這是預設的。

情報遞歸是通往戰略壟斷的途徑。

儘管存在危險，但情報遞歸仍然存在

對於尋求超越競爭對手的國家來說，這是一個強大的誘惑。如果這個過程以足夠快的速度領先以產生超級智慧，結果可能是戰略壟斷。即使這些改進不是爆炸性的，**arecursion** 仍然可以以足夠快的速度提升能力，以超越競爭對手，並有可能實現技術主導地位。然後，先發優勢可能會持續數年或無限地促使各國為追求這一利益而承擔更大的風險。

地緣政治競爭壓力導致高度的失控風險承受能力。在冷戰時期，「寧死總比紅」這句話暗示，輸給對手被認為比冒著核戰爭的風險更糟糕。在未來的人工智慧競賽中，類似的推理可能會促使官員容忍兩位數的失去控制的風險，如果替代方案（落後於競爭對手）似乎不可接受。如果選擇是赤裸裸的——冒著全能或失敗的風險——有些人可能會賭一把。由多個相互競爭的大國執行，這相當於全球俄羅斯輪盤賭，並將人類推向令人震驚的毀滅可能性。與此形成鮮明對比的是，在納粹德國戰敗後，曼哈頓計劃的科學家們擔心第一個原子裝置可能會點燃大氣層。羅伯特·奧本海默

（Robert Oppenheimer）問亞瑟·康普頓（Arthur Compton）可接受的閾值應該是多少，康普頓將其設置為百萬分之三（“6σ”閾值）——任何更高的閾值都太冒險了。計算表明，實際風險低於康普頓閾值，因此測試繼續進行。我們應該努力使我們的風險承受能力保持在康普頓閾值附近，而不是在兩位數的範圍內。然而，在沒有協調的情況下，狀態是否觸發遞歸取決於它們失去控制的可能性。失去控制的前景表明，在推動新技術開發過程中，“優勢並不同於安全”^[18]，但戰略壟斷的驅動力可能會壓倒謹慎，有可能將最終勝利交給人工智慧本身，而不是任何國家。

因此，隨著社會逐漸將決策權交給自動化系統，這些系統變得不可或缺，但陰險地獲得了越來越有效的控制，因此可能會在結構上出現失控。它可能是有意發生的，例如流氓行為者釋放 AI 來造成傷害。它也可能是偶然發生的，當快速移動的智慧遞歸循環反覆出現時。只需要一個失控事件就會危及人類安全。

隨著人工智慧不斷發展並接近專家級能力，它可能會重新定義國家競爭力，使其基於一個國家獲得人工智慧晶元的機會，並且它可能會發現一種「超級武器」，使一個國家能夠擁有戰略壟斷地位。此外，AI 的一般性和雙重用途性質放大了現有風險，例如生物恐怖主義和對關鍵基礎設施的網路攻擊。不幸的是，攻擊者對關鍵基礎設施的生物恐怖主義和網路攻擊具有強大的優勢。因此，訪問可以設計大規模殺傷性武器的 AI 系統必須受到限制。此外，有多種途徑會導致失去對強大 AI 系統的控制。這些因素意味著人工智慧對國家安全的重要性不僅將變得不可否認，而且至少與以前的大規模殺傷性武器一樣關鍵。

3.4 現有的人工智慧策略

各國在努力應對恐怖主義威脅、破壞穩定的武器化能力以及失去對 AI 的控制的幽靈方面，面臨著如何在不斷變化的環境中保護自己的艱難選擇。在這種背景下，三個提案獲得了突出地位：第一個提案解除了對開發和傳播的所有限制，將 AI 視為另一個計算機應用程式；第二項設想了當專案越過危險門檻時自願停止，希望每個大國都能集體退出；第三種主張將開發集中在一個政府主導的單一專案中，尋求在全球範圍內的戰略壟斷。每條路徑

它自身也有風險，要麼帶來惡意使用風險、無用條約，要麼引發破壞穩定的主導地位。在這裡，我們簡要研究了這三種策略並強調了它們的缺陷。

1. 不干涉（“Move Fast and Break Things”，或“YOLO”）策略。該策略主張對 AI 開發人員、AI 晶片和 AI 模型不設限制。這一戰略的支援者堅持認為，美國政府沒有對人工智慧公司提出任何要求——包括武器化能力測試——以免它限制創新並讓中國獲勝。他們同樣反對對人工智慧晶元的出口管制，聲稱這些措施將集中權力並實現一個世界政府；在他們看來，這些籌碼應該賣給任何有能力支付的人，包括對手。最後，他們鼓勵繼續公開發佈先進的美國模型權重，認為即使中國或流氓行為者使用這些 AI，也不會產生真正的安全威脅，因為他們堅持認為，AI 的能力在防禦方面佔主導地位。從國家安全的角度來看，這既不是一個可信的戰略，也不是一個連貫的戰略。

2. 暫停策略。自願暫停策略建議停止 AI 開發——立即停止或一旦檢測到某些危險功能，例如駭客攻擊或自主作。支持者認為，如果 AI 模型測試超過危險閾值，大國將暫停他們的計劃。然而，軍隊恰恰渴望這些危險的能力，這使得相互的克制變得難以置信。即使有條約，缺乏核查機制 [19] 也意味著條約將毫無意義；雙方都害怕對方的秘密工作，只會繼續。沒有武力威脅，條約將被違背，一些國家將尋求情報遞歸。這種動態讓人想起之前的軍備控制困境，使自願暫停更像是一種願望，而不是一個可行的計劃。

3. 壟斷戰略。壟斷戰略設想了一個項目確保對 advanced AI 的壟斷。一個較少被引用的變體——人工智慧的 CERN 讓人想起原子時代的巴魯克計劃——建議由一個國際聯盟來領導 AI 開發，但這並沒有引起政策制定者的興趣。相比之下，美中經濟與安全審查委員會 [20] 提出了一條更具攻擊性的道路：建立超級智慧的曼哈頓計劃。這樣的專案將援引《國防生產法》（Defense Production Act），將人工智慧晶元引入由頂級研究人員組成的美國沙漠大院，其中很大一部分必須是中國公民，其既定目標是發展超級智慧以獲得戰略壟斷。然而，這種設施很容易被衛星觀察到，並且容易受到先發制人的攻擊，這不可避免地會引起警覺。一旦實現超級智慧，中國不會坐以待斃，等待接受美國的指令，也不會等待失去控制的風險。曼哈頓計劃假設競爭對手會默許持久的不平衡或全能，而不是採取行動來阻止它。一開始推動超級武器和全球控制可能會促使敵對對策並加劇緊張局勢，從而破壞該戰略旨在確保的穩定性。

敵對國家、流氓行為者和失去控制的風險需要的不僅僅是一種補救措施。我們提出了三個相互關聯的工作方向。首先是威懾：類似於 MAD 核僵局的對峙，在這種僵局中，任何大國都不能將人類安全賭上肆無忌憚地爭奪主導地位，而不期望破壞活動。其次是防擴散：正如大國長期以來一直拒絕向恐怖分子提供裂變材料、化學武器和生物製劑一樣，人工智慧晶元和可武器化的人工智慧系統同樣可以遠離流氓行為者。最後，競爭力：各國可以通過各種措施來保護其經濟和軍事實力，包括為人工智慧代理和國內人工智慧晶元和無人機製造提供法律護欄。我們的超級智慧戰略，即多極戰略，與冷戰時期的威懾、不擴散和遏制框架相呼應，適應了人工智慧的獨特挑戰。

使用相互保證 AI 故障（MAIM）進行威懾

在核時代，最初的壟斷追求——一個國家尋求不受挑戰的核武器控制權——最終讓位於被稱為相互保證毀滅（MAD）的威懾僵局。隨著核武庫的成熟和相互毀滅的能力變得不可否認，各國最終




圖 3.3：美國超級智慧曼哈頓專案的可能結果。升級的一個例子途徑：美國計劃在沒有被削弱的情況下超過了中國，並保持了對遞歸的控制，但沒有獲得超級智慧或超級武器。儘管全球力量變化不大，但北京譴責華盛頓的戰略壟斷計劃是嚴重的升級。超級智慧曼哈頓專案的典型結果是極端升級，而全能滅絕是可預見的最糟糕的結果。

承認任何壓制所有反對派的大胆嘗試都有可能招致先發制人的打擊。類似的相互戰略脆弱性狀態在 AI 中若隱若現。如果一個敵對國家競相走向戰略壟斷，國家不會坐視不理。如果敵對國家失去控制，生存就會受到威脅；或者，如果敵對國家保持控制權並且 AI 很強大，則生存會受到威脅。擁有更強大 AI 的競爭對手將構成嚴重的國家安全緊急情況，因此超級大國不會接受 AI 能力的巨大劣勢。各國不會等待競爭對手將超級智慧武器化來對付他們，而是會採取行動來禁用具有威脅性的 AI 專案，從而產生一種可能被稱為相互保證 AI 故障（MAIM）的威懾動態。

4.1 MAIM 是預設制度

禁用競爭對手的 AI 專案的路徑。意圖阻止人工智慧戰略壟斷的國家可以採用一系列策略，從間諜活動開始，情報機構悄悄獲取有關競爭對手人工智慧專案的詳細資訊。知道目標是什麼，他們可能會進行秘密破壞：位置合理或勒索的內部人員可以篡改模型權重或訓練數據或 AI 晶片製造設施，而駭客則悄悄地降低訓練過程的品質，使 AI 在完成訓練時的性能之善可陳。這與旨在秘密破壞伊朗核濃縮計劃的 Stuxnet 類似。當微妙之處被證明過於限制時，競爭對手可能會升級為公開的網路攻擊，以數據中心晶元冷卻系統或附近的發電廠為目標，直接（如果明顯）破壞開發。如果這些措施動搖，一些領導者可能會考慮對數據中心進行動能攻擊，認為允許一個行為者冒險支配或摧毀世界是更嚴重的危險，儘管動能攻擊可能是不必要的。最後，在危急情況下，各國可能會通過攀登現有的升級階梯或威脅非 AI 資產來訴諸更廣泛的敵對行動。我們將針對競爭對手 AI 專案的攻擊稱為「致殘攻擊」。

預防致殘的不可行性。由於目前無法保護地上數據中心免受高超音速導彈的攻擊，因此尋求保護其人工智慧戰略壟斷專案的國家可能會試圖將數據中心深埋在地下以保護它們。在實踐中，成本和時間令人生畏，並且漏洞仍然存在。施工時間可以延長到標準數據中心建設的三到五倍，相當於額外的幾年。成本也膨脹，從專案的 AI 晶片中轉移資金，並將總支出推高至數千億美元。為世界上最大的地下超級計算機進行冷卻會帶來複雜的工程挑戰，這些挑戰遠遠超出了小型地下設置的要求。如果超級計算機需要數量級的 AI 晶片擴展，那麼改造該設施將變得非常困難。即使是那些有財富和遠見的人

MAD 與 MAIM




圖 4.1：MAIM 的戰略穩定性可以與相互保證毀滅（MAD）相提並論。注意 MAIM 並沒有取代 MAD，而是描述了另一個共同的漏洞。一旦 MAIM 成為常識，MAD 和 MAIM 都可以描述當前超級大國之間的戰略態勢。

走這條路仍然會面臨內部威脅和駭客攻擊的巨大風險。此外，在漫長的施工階段，整個專案可能會遭到破壞。最後，各州可以威脅非 AI 資產，以便在項目上線之前很久就阻止該專案。

MAIM 是預設設置。相對容易進行（網路）間諜活動和破壞競爭對手破壞穩定的 AI 項目會產生某種形式的威脅。就像核競爭對手得出結論認為先發制人可能會引發自身毀滅一樣，尋求人工智慧壟斷同時冒著失去控制的風險的國家必須假設競爭對手會在他們的專案接近完成之前癱瘓他們的專案。如果任何競爭對手認為其 AI 專案構成不可接受的風險，那麼一個州可以預期其 AI 專案將被禁用。這種動態無需冗長的條約談判即可穩定戰略格局——所需要做的就是各國集體認識到他們的戰略形勢。最終效果可能是一種僵局，它推遲了超級智慧的出現，減少了許多失控的情況，並削弱了確保戰略壟斷的努力，就像曾經限制核軍備競賽的相互確保毀滅一樣。

4.2 如何維持 MAIM 制度

各國最終開始接受這種相互威懾，雖然這似乎是核武庫堆積的自然副產品，但需要有意識地維護。每個超級大國都認識到，先進的防禦措施——特別是反彈道導彈（ABM）系統——可以瓦解阻止任何一方進行災難性先發制人的脆弱平衡。他們通過保護彼此的脆弱性來應對，最終形成了 1972 年的《反導條約》。以此類推，我們不應該讓今天的 MAIM 默認條件任由運氣：潛在的壟斷者，賭不會導致全能，可以預期他們的專案會被癱瘓。便

試圖強化大型數據中心是非常令人望而卻步和不明智的，僅憑謠言就可以引發人們對競爭對手將危及國家安全和人類安全的擔憂。不追求此類防禦工事的正式諒解有助於保持對峙的穩定。我們現在討論遏制意外升級和限制附帶損害的其他措施，以便 MAIM 不會演變成更廣泛的衝突。

保持理性的決策。正如核對手曾經在發射之路上繪製出每個梯級以限制誤解一樣，人工智慧力量必須澄清間諜活動、秘密破壞、公開的升級階梯

網路攻擊、可能的動能打擊等等。為了保持威懾力，雙方都必須做好致殘準備，確保任何致殘行為（例如網路攻擊）都不會被誤讀並導致不必要的升級。然而，如果流氓政權或極端主義派系獲得大量 AI 晶片，那麼升級的明確性幾乎沒有威懾價值。防止 AI 晶片走私的措施使決策權掌握在更負責任的國家手中，而不是流氓行為者手中，這有助於保持 MAIM 的威懾價值。與 MAD 一樣，MAIM 要求將破壞穩定的 AI 能力僅限於理性的行為者。

擴展 AI Project 網路攻擊的武器庫。為了避免訴諸動能攻擊，各國可以提高通過網路攻擊來破壞穩定的 AI 專案的能力。他們可以識別 AI 開發人員的專案或收集有關 AI 開發人員科學家的專業活動的資訊。要監視大多數公司的 AI 專案，所需要做的就是 Slack 或 iPhone 零日軟體漏洞。狀態還可能毒害數據、破壞模型權重和梯度、破壞處理故障 GPU 的軟體，或破壞冷卻或電源系統。訓練運行是不確定的，即使沒有錯誤，其結果也很難預測，從而為許多網路攻擊提供了掩護。與動能攻擊不同，其中一些攻擊幾乎沒有明顯的入侵跡象，但它們可以嚴重破壞不穩定的 AI 專案，而外交影響最小。

在遠端位置構建資料中心。在核時代，超級大國故意將導彈發射井和通信設施放置在遠離主要人口中心的地方。以此類推，這種城市避讓原則建議將大型 AI 數據中心放置在偏遠地區。如果發生激進的致殘行動，該行動不會使城市陷入交火。

區分破壞穩定的 AI 專案和可接受的使用。致殘攻擊的威脅使各國有槓桿要求競爭對手採取透明度措施，例如檢查，因此它們不需要僅依靠間諜活動來決定致殘是否合理。協調可以說明各州降低僅運行面向消費者的 AI 服務的數據中心癱瘓的風險。相互觀察的方法與《開放天空條約》的精神相呼應，該條約採用非武裝飛越來表明雙方都沒有隱藏導彈部署。本著類似的精神，提高透明度可以保護更廣泛的日常 AI 服務生態系統，並降低全面破壞的風險。

AI 輔助檢查。推測性但越來越合理可靠、保密的 AI 驗證器提供了一種途徑，可以確認 AI 專案是否包含機密材料。通過現場分析代碼和命令，AI 可以發佈保密報告或簡單的合規性判決，除了設施是否正在創建新的不穩定模型之外，可能不會再考慮任何事情。鑑於無意中收集或洩露信息的危險，人類無法輕易地扮演相同的角色，因此人工智慧可以重塑安全性和透明度之間的經典緊張關係 [21]。來自這些 AI 檢查的資訊可能有助於將任何潛在的衝突局限於 MAIM 的 escaloation ladder 階梯，而不是升級為人口的滅絕。這樣的機制可以在遙遠的將來提供幫助當 AI 開發需要較少的集中化或需要較少的計算資源時。

對許多數據中心的大規模攻擊; 威脅非 AI 相關資產
升級為更廣泛的敵對行動
對數據中心的動量攻擊或 相應的發電廠
Kinetic Threshold
對數據中心或相應發電廠的網路攻擊;刪除
法典
公開破壞閾值
模型重量被盜;秘密攻擊，降低不穩定 AI 的訓練運行
專案;網路攻擊導致 GPU 失敗的頻率更高
隱蔽破壞閾值
對 AI 開發人員工作區通信、人員設備以及 導彈庫的網路攻擊;不會洩露專有代碼 或機密材料

通過單邊資訊獲取（間諜）、多邊資訊獲取（驗證）、單邊致殘（破壞）和多邊致殘（聯合關閉開關），可以使MAIM更加穩定。在這些情況下，相互保證的人工智慧故障不需要演變成相互保證的人類結構。

默認情況下可能會出現破壞穩定的 AI 專案的對峙，但這並不意味著要持續幾十年或成為無限期的僵局。在對峙期間，尋求從創建更強大的 AI 中獲益的國家有動力提高透明度並採取驗證措施 [22]，從而降低破壞或先發制人攻擊的風險。在結論中，我們說明瞭這種僵局如何結束，讓 AI 的好處在沒有全球不穩定的情況下增長。

本節總結了本文的主要思想。讀者可以跳到結論，或閱讀以下兩節來討論不擴散和競爭力。



圖 4.3：由於配備人工智慧的恐怖分子可能造成的危害規模空前，因此需要幾道防線才能切實防止擴散。

防擴散

信奉相互破壞邏輯的國家可以通過限制彼此的意圖來阻止彼此。但是，由於流氓行為者更難預測，我們還有第二個當務之急：限制他們的能力。就像《不擴散條約》聯合國大國防止裂變材料落入恐怖分子手中一樣，各國也可以在人工智慧問題上找到類似的共同點。國家可以通過計算安全、資訊安全和 AI 安全來限制流氓行為者的能力，每個行為者都針對 AI 開發和部署管道的關鍵要素。

計算安全是關於確保將 AI 晶片分配給合法行為者以用於合法目的。這與為限制裂變材料、化學武器和生物製劑的傳播而採取的出口管制相呼應。

資訊安全涉及保護構成 AI 核心智慧資產的敏感 AI 研究和模型權重。保護這些元素可以防止無端傳播和惡意使用，與在 WMD 環境中保護敏感資訊所採取的措施並行。

AI 安全側重於實施保護措施，使 AI 模型可控可靠，從而保護其在民用環境中的應用。如果使用 AI 來自動化 AI 研究，則廣泛的監測和控制措施可以降低失控的風險。確保 AI 系統能夠抵抗縱或不造成災難性事故，這與旨在防止事故和未經授權使用災難性軍民兩用技術的國內保障措施相一致。

通過將不擴散大規模殺傷性武器的行之有效的策略應用於人工智慧領域，我們的目標是解決人工智慧開發和部署中固有的挑戰。此防擴散手冊提供了一個結構化的




圖 5.1：晶元是創建和運行 AI 的基礎。很少有公司能夠成功生產出可以運行 Frontier 模型的 GPU。大多數 AI 計算主要集中在大型數據中心。

保護輸入（AI 晶元和研究思路）和輸出（模型權重和 AI 系統本身）的方法，從而保護 AI 管道的每個關鍵元件。

5.1 計算安全性

AI 的進步取決於對強大計算資源（通常稱為“計算”）的訪問。這些 AI 晶片通過複雜和集中的供應鏈製作，對於訓練大規模 AI 模型至關重要。隨著計算成為經濟和國家安全不可或缺的一部分，其分佈變得至關重要。計算安全的主要目標是像對待濃縮鈾一樣對待先進的 AI 晶片。我們研究了計算安全的歷史先例，並提出了一些策略，以可靠地瞭解高端 AI 晶片的位置，並防止它們落入流氓行為者之手。

從歷史上看，各國都試圖通過限制其最關鍵的組成部分來遏制災難性軍民兩用武器的傳播：用於核武器的裂變材料、用於化學武器的化學前體和用於生物武器的生物製劑。為了實現這一目標，他們使用了出口控制，我們可以將其應用於 AI 領域。限制計算會大大限制流氓行為者的能力，因為正如我們將要論證的那樣，計算是 AI 能力的核心決定因素。

WMD 輸入的導出控制件。各國對關鍵材料和技術的流動進行監管，以防止它們落入壞人之手。對於核武器來說，這意味著控制濃縮鈾和鈾等裂變材料。國際協議和組織，如核供應國集團，協調這些控制措施，以監測和限制這些材料的出口。仔細跟蹤貨物，在運輸前後測量數量，並共用有關可疑活動的資訊。Aus-tralia Group 是一個非正式的國家聯盟，致力於協調出口管制，以防止化學和生物武器的擴散。出口管制使大規模殺傷性武器災難在歷史上罕見，它們也可能有助於防止人工智慧災難。




圖 5.2：Compute 是 AI 能力最強大的跟蹤器。

在 AI 的背景下，這意味著控制對 AI 晶片和用於製造這些晶片的元件的訪問。雖然一些出口管制已經到位，但我們需要提高這些管制的穩健性和徹底性。

Compute 作為 Fissile Materials 或 Chemical Precursors 等中心輸入。AI 晶片鏡像其他 WMD 輸入。AI 晶片需要複雜的製造工藝和大量資源，類似於鈾濃縮。同樣，計算量在很大程度上決定了 AI 的能力，就像 offissile 材料的數量會影響核武器的當量一樣。

AI 的進步與計算密切相關。領先的 AI 公司將絕大部分支出用於計算，遠遠超過研究人員或數據採集支出。NVIDIA 在 2024 年的收入飆升凸顯了計算在 AI 中的關鍵作用。

更多的計算使模型更智慧。有證據表明，計算是推動 AI 性能的主要因素。分析顯示，使用的計算量與 AI 模型在標準基準上的性能之間存在驚人的相關性（超過 95%）[23,24]。這種關係通過“縮放定律”正式化，表明隨著計算資源的增加，AI 性能會持續提高。這些縮放定律在 15 個數量級的計算中（以 FLOP 為單位）中都適用——

1,000,000,000,000,000 — 表示未來的進步將繼續以指數級方式推動不斷增長的計算量。結果是計算上的導出控制大大限制了流氓行為者的能力。

與演算法和數據的無形方面不同，由物理 AI 晶片體現的計算可以接受直接控制。這種物理性質使我們能夠知道 AI 晶片的位置並防止它們走私。我們可以通過兩種主要機制來管理其分發：導出控制和固件級安全功能。

5.1.1 導出控制

下面，我們將解釋許可框架和更嚴格的執法如何幫助我們追蹤每一個 AI 晶片和阻止走私。

記錄保存。要瞭解每個 AI 晶片的位置，可以通過許可制度進行更徹底的出口管制。利用現有的框架和機構，如工業和安全域，高端人工智慧晶元的銷售商將申請識別晶元、其接收者和任何預期轉讓的許可證。具有良好合規記錄的實體可能會獲得豁免，條件是他們將每次轉售或搬遷都通知當局。由於此過程依賴於熟悉的基礎設施，因此可以迅速引入，使官員能夠在不阻礙合法交易的情況下跟蹤晶元。



圖 5.3：防篡改

執法。為了遏制走私，可以通過加強執法來加強出口管制。例如，新加坡政府最近通過了《防篡改法案》，要求晶片製造商在晶片中植入防篡改功能，以確保晶片在整個生命週期中保持安全。根據有效許可證購買人工智慧晶元，然後將它們非法轉移到中國。更多的執法人員被指派進行面對面的合規訪問和最終用途檢查，將發現任何此類偏差，因為晶元的實際位置不再與申報的庫存相匹配。為了說明執法人員，來自數據中心的防篡改攝像頭饋送可以確認申報的 AI 晶片仍在現場，從而暴露任何走私行為。未申報的數據中心可以通過衛星圖像輕鬆檢測到，並成為檢查目標。在未經授權的人手中發現的任何晶元都會觸發處罰，例如罰款、刑事指控或禁止將來向違規方發貨。此外，被宣佈無法運行或過時的 anyAI 晶片將進行經過驗證的退役，就像處理化學或核材料一樣，確保這些據稱已報廢的 AI 晶片不會被悄悄轉售。通過加強檢查並對違規行為施加有意義的後果，各國提高了秘密轉移的成本，並將高級計算的傳播限制在可能威脅安全的群體中。

5.1.2 固件級功能

出口管制仍然是遏制高端人工智慧晶元傳播的堅實支柱，就像它們在化學或生物領域的兩用投入一樣。由於 AI 晶片是人類設計的產品，而不是惰性原材料，因此各國可以通過使晶片能夠驗證其周圍環境並在被篡改時自行鎖定來補充出口管制。此功能可通過固件更新實現，固件更新會修改最接近硬體的代碼，而無需進行任何物理重新設計。NVIDIA H100 等 AI 晶片已經採用了保護隱私的企業安全措施，例如機密計算和可信執行環境。然而，將這些現有的安全功能應用於國家安全可以拓寬視野：achip 可以檢測到它已越過未經授權的邊界或已被篡改，然後禁用其關鍵功能。借助精心設計的固件，狀態可以進一步阻止走私計算的嘗試，使用我們在下面描述的功能。

地理定位和地理圍欄。 AI 晶片可以設計為確定和報告它們的地理位置。通過測量來自多個地標的信號延遲，晶元可以在數十到數百公里內驗證其位置，這足以確定它是否在正確的國家/地區。如果晶片移動到未授權的區域，它會自動停用或限制其功能。這使得未經授權的各方走私或濫用 AI 晶片更具挑戰性，因為在不被發現的情況下重新定位它們變得更加困難。

許可和遠程證明。 實現 AI 晶片需要定期授權的系統從計算提供程式添加一個控制層。晶片可能需要定期獲取加密簽名才能繼續運行 [26]。這類似於 iPhone 上的功能，如果丟失或被盜，可以遠端停用該功能。使用安全、保護隱私的加密方法，晶元可以定期向受信任的機構確認它們沒有被篡改。如果晶元由於未經授權的重新定位、篡改或許可證過期而無法確認其授權狀態，則它可能會使其自身無法運行。這會降低被盜或走私硬體的長期可用性。

網路限制和作模式。晶片可以程式設計為僅與預定義的批准晶片清單連接。這通過防止大量晶元聯網而不被檢測，限制了構建未經授權的計算集群的能力。此外，除非明確授權，否則晶元可以通過限制某些功能來強制執行作模式，例如訓練或推理。通過要求明確授權以增加其網路規模或更改作模式，我們可以減少未經授權的計算能力擴展，這些擴展可能導致在既定協定之外破壞 AI 進步的穩定性。這可以補充出口管制執法官員的最終用途檢查。

物理防篡改。 除了固件之外，還可以在製造過程，以增加額外的防禦層。採用防篡改密封、加速器和其他物理安全措施可增強對未經授權訪問或修改的保護。例如，如果晶元檢測到篡改跡象或持續的意外移動，它可以停用或提醒當局。

局限性。雖然固件干預增強了我們對 AI 計算的控制，但它們並不是為了實現完美的安全性。這些機制有助於減少預期數量的走私功能晶元，並且不能完全替代出口管制。

隨著底層硬體級機制（如企業應用程式的可信執行環境）變得更加強大，用於補充導出控制的韌體也可以。由於晶元的快速發展，晶元會隨著時間的推移而被替換，新一代產品可以默認採用更高級的安全功能。這種逐步集成增加了更安全的 AI 晶片的比例，隨著時間的推移，未經授權的使用變得越來越困難和昂貴。

歷史上有這樣的例子，即敵對者在保護危險材料方面找到共同點。美國與蘇聯和中國在核、生物和化學武器方面的合作不是出於利他主義，而是出於自我保護。如果美國開始將先進的人工智慧晶元視為裂變材料，它同樣可能會鼓勵中國也這樣做。其理由類似於美國希望俄羅斯追蹤其裂變材料的原因：讓這些能力落入不確定的人手中，沒有人能從中獲益。蘇聯解體後，俄羅斯無擔保的濃縮鈾和化學武器構成了全球威脅，直到美國發起了 **Nunn-Lugar** 合作減少威脅計劃，說明遏制了他們。同樣，敦促中國保護其人工智慧晶元將承認避免災難的共同必要性，這些災難對任何人都沒有說明。

5.2 資訊安全

長期以來，保護敏感資訊一直是國家安全的關鍵，尤其是在大規模殺傷性武器方面。限制對敏感知識的訪問可以降低流氓行為者擴散的風險。核武器研究和設計細節的洩露構成了嚴重的風險。在生物技術領域，製造各種生物武器的協定並不公開共用。有權訪問此類信息的人員通過安全許可和可靠性計劃接受嚴格的審查和持續監控。風險很高，因為如果生物武器的“食譜”被公開傳播，它就會變得不可逆轉地擴散，並且可以無限期地被利用。

模型權重和研究思路作為核心 AI 資訊。在 AI 領域，主要部分敏感資訊是模型權重和研究思路。模型權重是涉及大量計算資源、複雜演算法和大型數據集的廣泛訓練過程的結果。它們類似於神經網路中的突觸連接，共同決定 AI 的功能。擁有這些權重將授予在沒有原始開發人員監督的情況下使用、修改和可能濫用 AI 的能力。攻擊者可以刪除保護措施，增強有害域中的功能，並將 AI 重新用於惡意活動。

資訊安全是一項技術和社會挑戰。從流氓行為者那裡獲得模型權重是一個多方面的挑戰，包括技術和社會維度。威脅不僅限於遠端駭客攻擊企圖，還延伸到內部威脅和間諜活動。僅有防火牆是不夠的。一個具體的例子涉及個人前往利益衝突的國家。例如，在 U.S.AI 公司工作的研究人員可能會回訪敵對國家，並面臨來自政府官員的壓力，要求在離開之前披露機密的研究想法。

此外，AI 組織中的一些人可能出於意識形態動機而發佈 AI model 權重，相信可以不受限制地使用技術。儘管對資訊自由的信念在許多情況下令人欽佩，但在國家安全的背景下，這一立場往往不適用。其他人則認為 AI 本身應該是自由的。一位人工智慧風險投資家表示，人工智慧「光榮地、本質上是不可控的」[27]。AI 教科書作者 Rich Sutton 曾表示，AI 應該被解放，因為“AI 的繼承是不可避免的”，“我們不應該抵制繼承”，並且“我們應該……鞠躬”[28]。

超能力證明資訊安全是難以置信的。我們建議加強資訊安全足以抵禦資源充足的恐怖組織和意識形態內部威脅，而不是抵禦世界上最有力量的民族國家。在更高級別關閉所有間諜活動途徑可能需要多年的高度關注 [29]，從而阻礙一個國家的人工智慧競爭力，並剝奪它現在為其頂級公司提供動力的跨國人才。例如，在大多數美國人工智慧公司中，中國公民的研究人員比例達到兩位數，而許多其他公司則很難獲得安全許可。集體淘汰他們會把這些人才趕到國外，並削弱美國的競爭力。剩餘的工作力需要被連根拔起並轉移到一個孤立的地方，以限制信息擴散。這些措施無效、會自我毀滅，並增加 MAIM 升級的風險。

雖然敵對超級大國的洩露令人擔憂，但公開發佈具有WMD能力的模型砒碼可能會構成更大的威脅。如果這些模型權重公開可用，它們就會不可逆轉地激增，使任何人都能獲得先進的人工智慧能力，包括恐怖分子和其他敵對的非國家行為者，他們更有可能製造生物武器。superpowerscan 並沒有試圖成為唯一擁有有能力的 AI 的國家，而是將他們的競爭引向其他領域，例如生產 AI 晶片以獲得經濟實力和製造無人機以獲得軍事力量。

5.2.1 如何提高資訊安全性

應對這些挑戰需要多層次的協調努力。可以在公司層面實施措施，以增強計算集群安全性並建立內部威脅計劃；在政府層面，通過強制進行滲透測試和促進威脅情報共用；在國際層面，通過達成協定來防止高風險 AI 模型的擴散。

公司措施：增強數據中心安全和內部威脅計劃。

AI 公司

需要採用嚴格的資訊安全實踐來保護模型權重和研究思路。這涉及幾個關鍵行動：實施深度防禦策略至關重要，將多個防禦策略分層，以便即使一道防線失效，關鍵資訊也是安全的。早期措施包括強制執行多因素身份驗證、在公司內部演示期間關閉百葉窗，以及確保在人們離開計算機幾分鐘時自動鎖定所有設備的螢幕。遵守最小許可權原則可確保唯一有權訪問模型權重的人員是需要它們的人員。公司還可以聲明他們已在其 AI 權重中嵌入了後門；因此，如果對手竊取並使用這些權重，對手可能會在不知不覺中將自己暴露在漏洞中。這樣的聲明可能是一種戰略欺騙，也可能反映了所採取的真正措施。

政府角色：協助提供威脅情報。

政府可以通過以下方式說明 AI 開發人員

使他們能夠徹底審查潛在員工並共用威脅情報。今天的法律限制，即由於害怕歧視性做法而阻止嚴格的背景調查，可以修改，以便公司可以在批准之前評估安全風險。另外，安全機構還了解對手的駭客攻擊策略和滲透方法，而這些方法很少向私營公司披露。通過共用有關對抗性策略和新出現的風險的情報，政府使公司能夠更好地防範間諜活動和網路攻擊。可以通過 AI 安全研究所為 AI 行業建立類似於網路安全風險資訊共享計畫（CRISP）的計畫，促進知識共用以應對高級威脅。一個全面的計畫將包括共用有關被解僱的 AI developer 員工的信息，這些員工被確定存在高安全風險。此外，此類舉措鼓勵 AI 公司相互之間以及與政府機構共用有關安全事件、可疑人員和最佳實踐的資訊，從而形成集體防禦機制。

國際協定：為開放重量 AI 病毒學家建立紅線。

在國際

級別，可以形成協定以建立有關 AI 模型權重傳播的明確界限。例如，可以達成共識，禁止發佈超過某些能力閾值的模型，例如相當於專家級病毒學家的模型。此類 AI 系統不受控制的擴散可能使個人或團體能夠設計病原體，從而構成全球風險。

從《禁止生物武器公約》（BWC）中吸取教訓，各國認識到防止威脅國際安全的技術擴散是共同的當務之急。生物武器，即「窮人的原子彈」，是高度不可控的，在大規模殺傷性武器中是獨一無二的，因為它們具有自我複製的能力。通過明確禁止釋放專家級病毒學家 AI 的權重，國際社會可以降低這些能力落入恐怖分子手中的風險。

保護與 AI 相關的資訊（模型權重及其背後的想法）需要在多個層面上採取行動。通過加強內部防禦，與政府合作打擊恐怖主義

網路攻擊以及建立國際協定以防止擴散，我們可以降低高級 AI 能力不可逆轉地擴散到流氓行為者的風險。然而，即使計算資源和 AI 資訊得到保護，我們仍然必須保護面向公眾的 AI 系統不被恐怖分子利用。這讓我們想到了 AI 安全的話題。

5.3 AI 安全

5.3.1 惡意使用

在化學、生物和核技術等危險領域，保護措施可防止未經授權的使用。如果一些化工廠檢測到未經授權提取有害化學品，他們會自動注入中和劑。DNA 合成服務對客戶進行篩選，以阻止有害病原體的產生。核電廠在運營時承擔著避免災難的嚴格責任。這些技術、作和立法措施強調了對災難性軍民兩用技術採取保障措施的重要性。隨著人工智慧變得越來越強大，強大的保護措施將變得必要，以防止事故發生並確保它們不會被流氓行為者利用。

AI 可以通過多層方法得到保護，包括技術模型級保護措施、運營保障措施（包括“瞭解你的客戶”協定）以及立法保障措施，例如強制性政府測試和責任澄清。

模型級保護措施可以相當健壯。最近的發展表明，模型級保護措施可以顯著地抵抗縱。拒絕訓練等技術涉及教 AI 系統拒絕說明恐怖主義活動的請求。輸入和輸出過濾通過在處理之前掃描使用者輸入以查找恐怖分子請求 [30]，並檢查 AI 輸出以阻止敏感資訊或有害作，從而增加了額外的安全層。斷路器是嵌入在 AI 架構中的機制，當它檢測到與武器化相關主題相關的處理時，它會中斷其作 [31]。這些組合方法已被證明是有效的，一些人工智慧系統在成功之前抵制了數萬次嘗試的規避 [32]。




圖 5.4：瑞士乳酪模型顯示了多種干預措施如何限制惡意使用。多層防禦可以補償彼此的弱點，從而降低整體風險水準。

通過瞭解您的客戶協定平衡訪問。為避免過度限制 AI 的有益用途，尤其是在科學研究中，實施瞭解您的客戶（KYC）協定可能是有效的。具有合法需求的研究人員，例如研究病原體的病毒學家，在經過適當驗證後，可以被授予使用雙重用途的能力。可以對最近創建的匿名帳戶實施保護措施，但對於企業客戶，可以刪除這些保護措施。這種方法反映了生物技術的現有實踐。

獲取危險生物材料需要正當理由和授權。KYC 措施還可以通過使不良行為者更難獲得訪問許可權來威懾惡意使用，因為他們需要繞過嚴格的身份驗證流程。此外，KYC 協定允許撤銷試圖濫用 AI 系統的使用者的訪問許可權，例如那些試圖通過越獄來規避保護措施的使用者。這使得惡意行為者反覆嘗試利用變得更具挑戰性，因為他們需要克服身份驗證才能重新獲得訪問許可權。

強制性政府保障措施壓力測試。強制性測試是處理高風險技術的行業的標準做法，例如核反應爐在投入運行之前所需的嚴格安全評估。同樣，在 AI 的背景下，政府的參與對於徹底測試 AI 保障措施是必要的，特別是因為與大規模殺傷性武器相關的許多知識都是機密的。當局可以進行受控評估，以評估人工智慧系統是否可以協助非專家製造化學、生物、放射、核或網路武器，或顯著降低專家的門檻。雖然自動測試速度更快並有助於可重複性，但它們對於風險評估不是必需的，手動測試就足夠了。測試可確保 AI 開發人員解決保護漏洞，並確保他們的系統不會危及國家安全。

激勵無許可的持續改進。

與核能和化學工業不同，

如果許可和政府批准是運營的先決條件，那麼 AI 技術的快速發展可能會使傳統許可更具挑戰性。AI 保護措施的最佳實踐每年都會發生變化，大多數政府機構缺乏確定新最佳實踐的專業知識。一個潛在的替代方案是建立一個基於責任的框架，以激勵開發人員不斷更新和改進他們的保護措施。如果開發者的 AI 系統被惡意用於造成重大傷害（例如協助製造大規模殺傷性武器），則開發者將承擔部分責任，從而產生強烈的動機主動加強保障措施。這種方法側重於闡明激勵措施，而不是強制要求特定的保護措施，鼓勵開發人員領先於新出現的威脅。

5.3.2 失控

保障措施降低了軍民兩用技術開發和使用過程中發生事故的風險。化工廠使用雙壁儲罐來儲存有害物質。控制棒和緊急堆芯冷卻系統可防止核電站熔毀。生物研究實驗室分為生物安全級別 1 到 4，每個實驗室都有越來越嚴格的安全程式，以安全處理危險病原體。從歷史上看，更好的保障措施可能有助於防止像博帕爾（印度的災難性化學品洩漏導致數千人死亡）和切爾諾貝利（蘇聯的核熔毀，放射性污染蔓延到境外）這樣的災難。

同樣，高度先進的 AI 系統的發展可能需要升級監控、控制和控制措施，以降低傳播不受控制的 AI 的事故風險。如果研究過程是自動化的，這些措施也可以應用於研究人員 AI，以確保開發安全地進行。

雖然核武器的發展建立在核物理學的嚴格基礎之上，但今天的 AI 研究通常是通過非理論的修補、“向牆上扔東西，看看什麼會粘住”和基於“共鳴”的評估來推進。創建尖端

AI 開發人員收集大量在線文本，在數以萬計的 AI 晶片上處理這些文本，並以廣島級爆炸的規模消耗能量。幾個月後，他們檢查了生成的模型，以發現哪些新的新興功能已經萌芽。AI 系統不是“設計”的，而是“成長的”。因此，他們偶爾會提供令人費解的結果也就不足為奇了，這些結果違背了創作者的控制或期望。當 Microsoft 在 2023 年推出其 Bing 聊天機器人“Sydney”時，它宣佈了對使用者的愛，並對許多其他使用者進行了威脅 [33]。

防止失控需要解決兩個問題。首先是確保可以控制單個 AI 系統。第二個是在 *intelligencerecursion* 期間控制 AI 代理的數量（在 Section 3.3.3 中引入）。我們將依次考慮這些。

控制 AI 的新興價值系統。當尖端人工智慧進行訓練時，它們會獲得連貫的、新興的價值系統[34]。默認情況下，這些價值系統表現出從未明確程式設計的錯位偏好。如果不糾正，一些像 GPT-4o 這樣的 AI 更喜歡 OpenAI 存在的 AI，而不是美國中產階級的生活。為了控制 AI 的值，輸出控制方法的工作原理是懲罰不受歡迎的行為並獎勵首選行為 [35, 36, 37]。這種方法可能是膚淺的——很像教精神病患者在不改變其更深層次價值觀的情況下更好地對假釋委員會撒謊 [38]。同時，表示控制 [39] 方法直接干預 AI 的權重和啟動以控制其內部思想。當一起應用時，只要開發人員在整個 AI 開發過程中仔細徹底地應用它們，就可以對當前的 AI 系統提供合理但不完美的控制。

通過這些技術，我們可以控制 AI 具有「人類價值」。人類價值觀的一個令人信服的來源是公民大會，而 AI 的價值觀將與議會投票的偏好保持一致。例如，澳大利亞公民大會將重視某些政策而不是其他政策，而美國的人工智慧將接受培訓，從公民大會表達的各種偏好中學習，並將這些偏好推廣起來，以取代他們自己的新興價值體系。通過整合通過審議和投票表達的價值觀，AIagents 可以反映出一組更具代表性和民主知情的偏好。這種方法融合了多種道德觀點，導致 AI 行為符合社會規範。定期更新可以使 AI 與不斷發展的價值觀保持同步。

儘管今天的單個 AI 系統可以得到合理的控制，但更可怕的危險在於管理智慧遞歸。

控制智慧遞歸。就像大型系統中的一群好心人可以一樣導致沒有人想要的緊急問題，在智慧遞歸期間安全地引導不斷發展的 AI 代理集體與控制一個固定的 AI 在本質上是不同的。控制單個 AI 需要透過 AI 研究開發的模型級控制方法，但控制智慧遞歸是一個需要系統級控制過程的棘手問題。智慧遞歸控制措施不是消除所有風險的“解決方案”，而是分層在一起以減少不受控制的結果的可能性。情報遞歸項目雖然目前不明智，但可以考慮實施以下措施。

模型級控制直接干預 AI 以塑造其功能和價值。這些措施可以限制 AI 的駭客攻擊能力，從而使自我滲透變得不那麼合理，並且可以將其注意力限制在眼前的任務上，而不是無意中激勵與長期目標相關的隱藏議程。通過調整內部值，開發人員可以使 AI 更誠實，更有可能服從人類。表示控制和輸出控制可以調整其功能和價值，但目前的方法僅具有中等可靠性，需要隨著 AI 系統的發展而發展。

裝箱通過調節 AI 到數據中心外部世界的通道來加強這種遏制。氣隙隔離伺服器的外部連接，使 AI 無法簡單地將自身複製到外部伺服器中，而沙箱將 AI 限制在一個合成環境中，它不能輕易突破其邊界。Boxingtechniques 還可能限制提供給 AI 的資訊，使它們的態勢感知能力有限，否則可能會進行顛覆性規劃。

監控增加了一層持續監督。測謊儀可以探測 AI 的思維模式，尋找欺騙的跡象。預測 AI 評估項目的保護措施在下一輪突破中動搖的可能性。AI 還可以觀察彼此的代碼和數據，掃描後門或可疑的指令。徹底的人工審核是最終的後盾，儘管它以人類的速度限制機器速度，大大減慢了開發速度。

模型級控制、裝箱和監控共同提供了對人工研究人員群體的一些控制。然而，由於人口將迅速發展，這些保障措施同樣需要迅速升級。AI 本身需要研究如何改進這些保護措施。

所有這些保障措施都需要付出代價。地緣政治競爭壓力可能導致實施和升級保障措施的優先順序降低。改進控制措施的研究、AI 模型紅隊和 AI 拳擊滲透測試會消耗計算，否則可能會加快 AI 開發速度。如果沒有人類檢查 AI 的決策或嘗試破譯其代碼或數據，那麼該專案就有可能偏離其指揮官的意圖。低風險容忍度可能是防止智慧遞歸超越其自身安全檢查的唯一原因。

我們的防擴散戰略分層多重防禦，而不是要求無懈可擊的安全保證（圖 5.4）。為 AI 晶片、電腦系統和 AI 系統尋求完全保證可能很棘手。相反，我們假設沒有單一的措施可以解決所有漏洞，並建議實施多種安全措施。對於計算安全性，我們討論了記錄保存、防篡改攝像頭、地理位置功能等。在資訊安全方面，我們建議使用多因素身份驗證、最小許可權原則、內部威脅程式等。對於 AI 保護措施，我們重點介紹了 outputfilters、瞭解您的客戶協議、強制性測試等。通過將 AI 開發和部署管道中的限制因素交織在一起，這些限制全面限制了災難性雙重用途 AI 能力向流氓行為者的擴散。

就像在核時代一樣，當雙方都意識到允許強大的技術脫離其控制或落入恐怖分子手中的危險時，自我保護可以導致合作。即使在其他領域遭到強烈反對，國家也無法從流氓行為者奪取人工智慧晶元或模型砒礪碼來引發無視威懾的災難中獲益匪淺。因此，不擴散成為一項共同的當務之急，而不是一種利他主義的做法，而是認識到沒有一個國家可以自信地獨自應對每一個威脅。通過出口管制、資訊安全和 AI 安全來保護 AI 的核心部分，大國可以防止災難性的流氓行為者的出現。

競爭力

通過威懾或核擴散實現的生存可以預防災難，但它本身並不能確保一個國家的未來。如果一個國家渴望塑造事件，而不僅僅是忍受事件，它就必須努力保持競爭力。在本章中，我們轉向競爭的關鍵目標，討論將人工智慧整合到軍隊中，通過保證對人工智慧晶元的訪問來加強經濟彈性，制定法律結構以有效管理人工智慧代理，以及在爆炸性經濟增長中保持政治穩定。




圖 6.1：在經濟和軍事領域快速、謹慎地採用人工智慧將成為國家實力的關鍵。

6.1 軍事實力

即使一個國家率先取得了突破，但如果它未能將這種能力整合到實際作中，它也可能落後[40]。英國在第一次世界大戰期間推出了第一輛坦克，但很快就被德國在第二次世界大戰中系統性地採用坦克所取代。同樣，即使超級智慧為全面的二次打擊導彈防禦系統提供了技術路線圖，其建造速度可能仍然取決於一個國家先前存在的工業能力。接下來，我們來看三個短期的當務之急

AI 在軍隊中的傳播：確保可靠的無人機供應鏈，小心翼翼地將 AI 融入指揮和控制，並將 AI 集成到網路攻擊中。

保障無人機供應鏈，減少誤解。儘管通用 AI 可能會帶來更大規模的危險，但無人機在現代戰場上佔據著更傳統但越來越關鍵的作用[41，42]。無人機便宜、敏捷、致命且分散，這些屬性使它們成為決心跟上軍事趨勢的國家不可或缺的屬性。然而，許多國家仍然嚴重依賴中國製造商提供關鍵的無人機和機器人零部件，如果這些零部件在適當的時候被扣留或中斷，它們就會容易受到攻擊。


即使一個國家確保了無人機的供應，如果無人機接近有爭議的線路或誤讀模稜兩可的信號，無人機的龐大數量和自主性也可能將衝突推向意想不到的領域。為了化解潛在的衝突，各國可以借鑒早期被證明有價值的做法，例如維持公開的危機熱線、安排例行交流和其他建立信任的措施。即便如此，大規模生產無人機和機器人將成為任何尋求在未來衝突中捍衛其地位的國家幾乎不可避免的步驟。

將 AI 擴散到命令和控制以及網路攻擊中。現代戰場需要從陸地、海洋、空中和網路領域的大量數據中快速做出決策。AI 系統可以比人類軍官更快地篩選這些流，從而誘使指揮官依賴自動判斷。同樣，在速度和成本上超過人類的 AI 駭客系統可以大大擴展軍隊執行網路攻擊的能力。

將人工智慧納入指揮和控制以及網路攻擊將顯著提高軍事能力，但這種動態可能會使“人在迴路中”淪為“接受、接受、接受”的反射性點擊，而有意義的監督被事件的速度所掩蓋。要求所有單獨的較低級別參與的人工批准可能不如確保對更嚴重的礮石分級攻擊的明確人工批准重要。然而，人類對關鍵軍事決策的監督仍然至關重要。人工後盾可以降低「閃電戰」的風險 [43]，類似於 2010 年的閃電崩盤 [44]，其中 AI 的一個小錯誤可能會在任何人類干預之前演變成破壞性的報復。

6.2 經濟保障

經濟安全是國家安全的基石，AI 將成為經濟安全的關鍵。通過支持國內人工智慧晶元生產和吸引來自國外的熟練人工智慧科學家，各國可以增強其韌性並鞏固其地位。



6.2.1 製造 AI 晶片

世界對臺灣高端人工智慧晶元的依賴構成了一個戰略漏洞。由於高端人工智慧晶元的供應鏈完全依賴臺灣，台灣構成了一個關鍵的瓶頸，可能會破壞一個國家在人工智慧方面的競爭力。許多分析人士認為，中國在未來十年入侵臺灣的可能性達到兩位數。除了在全球範圍內引發全球衝突和經濟動蕩外，這還可能嚴重擾亂 AI 晶片的供應。雖然西方擁有決定性優勢，但中國在 AI 晶片製造方面擁有極大的優勢。這使中國在 AI 能力方面獲得決定性優勢，並有可能成為 AI 晶片供應的關鍵樞紐。

中國一直在大力投資其國內晶元製造，每年分配的資源相當於美國的《晶元法案》[45]。這一承諾使中國能夠承受地緣政治衝擊，並有可能在 AI 發展方面領先於其他國家。相比之下，許多國家的人工智慧晶元供應仍然依賴臺灣，使自己面臨與地緣政治緊張局勢相關的風險。因此，中國入侵臺灣對西方開發和使用人工智慧的能力的損害要大於對中國的損害。

構建新技術的最重要資源不應完全在世界上最不穩定的地區之一生產。為解決這一漏洞，各國應該在本國領土上投資建設先進的人工智慧晶元製造設施。在國內建造此類設施需要更高的成本，但政府補貼可以彌合這一差距。通過激勵國內生產，各國可以保護其 AI 供應鏈，減少對外部資源的依賴，並提高其議價能力。此外，當 AI 代理產生明顯的經濟價值時，一個國家的經濟實力可能取決於其 AI 晶片的數量，而國內製造業可以擴大這種供應。

這一戰略舉措反映了歷史上控制關鍵技術的努力。在曼哈頓計劃期間，不僅在洛斯阿拉莫斯的核武器開發方面進行了大量投資，而且在橡樹嶺的鈾濃縮方面也進行了大量投資。同樣，確保獲得 AI 晶片需要在創新和製造基礎設施方面進行大量投資。

通過加強國內人工智慧晶元生產能力，各國可以提高其競爭地位和抵禦可預見的毀滅性失敗的韌性。我們現在轉向限制性而非建設性的 AI 晶片策略。

6.2.2 為 AI 科學家的移民提供便利

正如美國曾經在曼哈頓計劃期間利用移民科學家的才能一樣，美國在 AI 領域的領導地位在一定程度上也依賴於吸引來自國外的傑出 AI 科學家。在最近的一項調查中，在美國工作的非公民人工智慧博士中有 60% 報告了嚴重的移民困難，許多人表示這些挑戰使他們更有可能離開 [46]。隨著全球對人工智慧人才的競爭加劇，實施專為人工智慧科學家量身定製的可靠移民途徑將有助於確保美國始終處於人工智慧發展的前沿。通過為這些研究人員完善簽證和居留政策——與更廣泛的移民改革和南部邊境政策不同——美國可以在一個對國家安全和經濟實力日益重要的領域保持其優勢。

6.3 管理 AI 代理的法律框架

我們的法律體系是為治理人類而構建的，可以擴展到治理 AI 助手和 AI 代理。法律結構必須在創新需求與防止傷害的必要性之間取得平衡，而不是施加可能阻礙經濟安全進而阻礙國家安全的過度限制性措施。

6.3.1 對齊各個 AI 代理

長期以來，道德困境一直是激烈爭論的話題，目前還沒有明確的解決方案。然而，在缺乏關於個人應該做什麼的普遍答案的情況下，社會已經制定了法律制度來懲罰不可接受的行為並促進安全和繁榮。雖然沒有法律制度是完美的，但許多法律制度都共用了通常有效運作的基本原則。例如，法律禁止謀殺，政府執行合同，而造成傷害的人通常被要求提供賠償。法律框架並非旨在確保所有人的最佳行為；這樣的努力會過度限制個人自由，並被證明是無效的。然而，它們阻止了一些最糟糕的行為，讓社會利用非正式機構和經濟激勵措施來鼓勵有益的行為。

我們認為，相同的原則也適用於 AI。確定所有場景中 AI 行為的通用解決方案是棘手的。然而，我們不需要推遲對 AI 行為進行立法，直到關於

解析 AI 值。相反，我們可以開始制定原則來管理 AI 行為並防止有害行為，而不會過度限制各種 AI 的功能。

雖然有些法律並不直接涵蓋 AI（例如依賴於人類意圖和心理狀態的法律），但我們可以調整法律概念，為 AI 代理建立約束，以便它們遵循法律的精神。特別是，儘管許多法律取決於行為背後的心態或意圖（*mens rea*），但我們可以確保 AI 不會執行法律旨在禁止的行為（*actus reus*）。此外，通過將 AI 視為人類主體的助手，我們可以施加與已經應用於人類行為的約束相對應的限制，確保 AI 代理為社會做出積極貢獻，而不會造成不應有的傷害。

AI 行為的約束

我們對 AI 行為提出了一些類似於人類法律義務的基本約束，包括對公眾的義務，如防止傷害和不撒謊，以及對 AI 的人類主體的特殊義務。

對公眾的注意義務（合理注意）。AI 代理應採取與類似情況下合理的人相稱的謹慎程度，以防止傷害。這就是合理謹慎的法律概念。這包括避免可能預見在法律意義上造成傷害的行為——例如違反侵權法或刑法——而不仅仅是冒犯情感或參與有爭議的言論。合理謹慎的適用取決於具體情況，例如，提供有關武器材料的詳細資訊可能適合經過驗證的專業人士，但不適合未經審查的個人。

不撒謊的義務。AI 代理應避免發表他們知道是虛假的陳述。這對人類來說過於限制，因為在大多數情況下，人類可以互相撒謊，但對言論自由的寒蟬效應對 AI 來說就不那麼重要了。此外，由於 AI 可以進行測試，因此確定 AI 是否公然撒謊比確定 AI 是否對人類撒謊更可行。相反，它們應該被遵守一個更類似於禁止偽證和欺詐的標準，即使在臨時或專業的環境中也是如此。這與吹噓或戰略性遺漏等細微差別是分開的。AI 代理應避免公開的謊言，而是在必要時選擇不回答。

對委託人的注意義務（信託義務）。作為助手，AI 代理對其委託人負有特殊義務。他們應該忠誠行事，優先考慮委託人的利益，而不是同時進行自我交易或為利益衝突服務。此外，他們應該讓委託人合理地了解情況，提供相關信息，沒有關鍵遺漏，以實現知情同意。

自定義目標和市場驅動的變體

在這些受法律啟發的限制下，AI 代理的設計和作方式存在很大的多樣性空間。自由市場和消費者偏好可以塑造 AI 代理的具體目標和傾向。有些人可能會優先考慮速度和效率，以最少的修飾提供快速的結果，而另一些人可能會專注於提供全面、精心設計的回復。個性特徵（例如幽默、正式或矜持）也可以進行定製，以適應不同的使用者偏好和情境。例如，客戶支援 AI 可能會被程式設計為避免討論不相關的主題，從而保持對服務相關問題的關注。這種定製使 AI 代理能夠滿足不同行業用戶和個人偏好的不同需求。

將 AI 行為建立在法律原則的基礎上，為管理 AI 代理提供了一個務實的框架，確保他們以防損和維護社會標準的方式行事。在這些邊界內，定製和市場動態可以塑造 AI 代理的具體特徵，從而實現多樣性和創新。這種方法避免了強加狹隘或武斷的道德標準的陷阱。通過利用已建立的

法律概念和社會進程，我們可以以尊重個人自由的方式塑造 AI 行動，並營造一個多元化的環境，讓 AI 為社會做出積極貢獻，而不會受到不當限制。

6.3.2 對齊 AI 代理的集合

在線 AI 代理的出現將很快導致一個複雜的生態系統，這些實體在其中為使用者執行任務、進行金融交易、處理敏感資訊和簽訂合同——通常與眾多其他代理和系統互動。這種擴散帶來了重大挑戰：在與 AI 代理交互時，人們可能不知道它的運行位置、部署背後的實體或行為歷史。如果代理人造成傷害，尋求法律補救就成為一項艱巨的任務。

建立信任機制和機構。

為了應對這些挑戰，我們必須發展機械

在 AI 代理網路內加強信任和問責制。保險服務可以承保代理人互動中固有的風險，為潛在損失提供保障。通過將責任從使用者和開發人員轉移到保險公司，這些服務可以更廣泛地參與代理生態系統，同時降低財務風險。Action Firewall 服務可以監督和規範代理活動，充當篩選和監控 AI 代理發起的作的仲介。他們確保代理人遵守法律和道德標準，從而在與他們互動的各方之間培養信任。人工監督服務可以促進人工審查和批准 AI 代理決策。聲譽系統可以記錄和傳播有關代理行為的資訊，使各方能夠評估他們與之接觸的代理的可靠性。通過維護過去的互動和結果記錄，這些系統有助於識別始終如一地善意行事的代理人。調解和抵押安排提供了進一步的擔保，其中爭議通過公正的實體解決，代理人提供針對不當行為的保證。通過要求代理人提供抵押品，各方可以在違約時獲得賠償保證，而調解服務則有助於公平解決。

通過 ID 將 AI 代理與人類法人實體相關聯。

基本度量包括分配唯一的

標識元添加到 AI 代理，將它們錨定到人工支援的法人實體。這種聯繫確保了代理人不會匿名運作，並且明確劃定了責任界限。AI 代理應避免提供服務或與其他代理交換資源，這些代理不與受人工監督的合法法人實體無關，這些實體不僅僅由 AI 代理本身支援。

推遲考慮 AI 權利。

必須澄清的是，這種方法並不意味著授予

權利或直接對 AI 代理本身負責。向 AI 代理授予許可權充其量只是模稜兩可的好處，具有明顯而重大的缺點。AI 代理可以在幾秒鐘內複製和部署，而將人類培養到成熟則需要幾十年的時間。授予 AI 許可權可能會導致超出人類控制範圍的自主實體迅速激增。此外，人工智慧中的高智商本身並不同於道德辨別力；歷史記載了許多聰明的人，他們的行為沒有道德考慮。由於我們不太可能在短期內獲得關於 AI 意識的明確確定性，因此推遲考慮 AI 權利是謹慎的做法。通過推遲這一決定，我們避免了過早地向道德地位仍不確定的實體授予權利的相關風險。

通過建立法律框架和培養體制機制，我們可以避免出現混亂的人工智慧生態系統。將 AI 代理與人工支援的法人實體聯繫起來，並實施增強問責制和信任的系統，使我們能夠熟練地管理 AI 代理的廣泛部署所帶來的複雜性。

6.4 政治穩定

隨著 AI 更深入地融入社區，它帶來了挑戰，如果不加以解決，可能會破壞政治穩定。面對審查制度和錯誤資訊以及 rapid 造成的破壞

	低控制	介質控制	高控制
風險管理	加速 — 無限制	MAIM威懾擴散競爭力	暫停 AI
WeaponizableAI 權重在各州之間的分佈	所有人，包括流氓狀態（開放多極政權與負責任的國家權重）		戰略壟斷的單極政權（AI Manhattan Project）
政府對國內 AI 的控制	無參與	寬鬆立法（例如：強制檢測、責任澄清）	國有化
資訊安全	標準企業安全性	抵禦資金雄厚的恐怖組織	針對最有能力的民族國家的頂級程序進行保護
AI 自主性	解放	避免在可預見的將來授予權利	避免給予權利
AI 行為限制	AI 僅受現有法律約束	受法律精神約束的 AI（行使合理謹慎和受信責任）	神聖的 AI（如果某事可能有害或對某人造成冒犯，則拒絕）
歷史上的大規模殺傷性武器提案	《公約》生物武器	國際原子能機構、禁化武組織	巴魯克計劃

圖 6.3：低、中和高控制方法的比較。我們始終推薦 medium control 選項。

自動化對於保持國家競爭力至關重要。

6.4.1 審查和不準確的資訊

資訊生態系統的侵蝕。我們社會的結構是由共用信息的線索編織而成的。當不正確或誤導性的內容激增時，它會扭曲公眾的看法並導致有缺陷的集體決策。與此同時，嚴厲的審查制度會侵蝕對機構的信任並引發強烈反對。AI 具有雙重能力，可以生成大量錯誤資訊，並實現前所未有的監控和內容壓制水準。

AI 作為清晰的工具。在這一挑戰中，可以利用人工智慧來增強我們的資訊生態系統。可以訓練 AI 更好地使用當前資訊預測未來事件 [47]。通過調整 AI 系統以優先考慮準確性並斷言概率判斷（即使它們與流行觀點相矛盾），我們可以解決不受歡迎的真理被壓制的「伽利略問題」。隨著 AI 加快變革步伐並迎來快速變革，越來越準確的事實判斷對於防止社會脫軌勢在必行。

AI 預測可能比人類預測更便宜、更準確。當前的 AI 系統已經在某些類型的預測（例如地緣政治預測）中，最優秀的人類的準確性，很快他們就會大大超過他們。在各種領域測試預測 AI 將迅速提供 AI 預測跟蹤記錄的公開證據。由不同組織創建的預測 AI 可能會獨立得出類似的預測。這種趨同有助於澄清共識現實並提高信任度。

在危機期間使用 AI 進行預測。在危機時期，例如地緣政治緊張局勢或公共衛生緊急事件，AI 驅動的預測可以提供無黨派的見解，從而改進決策過程。通過提出諸如“何時會創造超級智慧”、“中國會在這十年內入侵臺灣嗎”和“這種策略是否可能增加第三次世界大戰的可能性”等關鍵問題，我們可以獲得有助於政策和高層決策的概率評估。

通過 AI Insights 為決策者提供支援。為各級領導者提供 AI 生成的預測可以改善治理。通過提供合理的預測並概述各種行動的可能後果，AI 可以支援在快速變化的場景中做出明智的選擇。說明特定干預措施如何降低災難概率的條件預測可以減少宿命論並鼓勵採取主動措施。雖然人工智慧加劇了錯誤資訊和審查的挑戰，但它也提供了強大的工具來加強我們的資訊生態系統並駕馭未來的不確定性。

國家安全威脅	戰略回應
權力基礎的轉移	競爭力（國內 AI 晶片製造）
破壞穩定的超級武器	威懾（MAIM）
恐怖主義	防擴散
釋放的 AI 代理	防擴散
控制侵蝕	競爭力（預測 + 受託責任）
遞歸控制喪失	威懾（MAIM）

圖 6.4：各種國家安全威脅概述和擬議的戰略應對措施。

6.4.2 自動化

自動化和政治穩定。隨著 AI 系統以前所未有的速度加速人類任務的自動化規模和速度下降，社會面臨著應對就業快速變化的艱巨挑戰。工作力重大轉型的歷史先例，如工業革命，在幾十年內展開，使人口和機構能夠適應。然而，即使是這個更漸進的過程似乎也可能導致了相當程度的破壞和短暫的失業。相比之下，人工智慧驅動的自動化可能會發生得更快，先進的系統很快就會在廣泛的職業中與人類的表現相媲美或超過人類。如果 AI 能力的速度超過了大部分工作力有效接受技能再培訓的速度，那麼職業再培訓等傳統解決方案可能被證明是不夠的。目前的社會安全網旨在解決偶發性或特定行業的失業問題，似乎無法管理同時影響多個行業的廣泛工作崗位流失。

不確定的贏家和輸家。隨著人工智慧取代了大部分工作力，由此產生的經濟成果將取決於人工智慧很快可以取代的任務數量、人工智慧執行這些任務的能力以及經濟瓶頸的重要性 [48]。如果瓶頸（例如建造工廠的法律要求）很強，那麼具有剩餘稀缺能力的人可能會獲得大部分經濟收益。但是，如果 AI 是高度通用的並消除瓶頸，那麼數據中心計算的擁有者就可以獲得大部分收益。

財富和權力分配。為了分享自動化的一些好處，政策制定者可以權衡諸如對 AI 服務徵收有針對性的加值稅，並輔以退稅等選項，但稅收政策的確切結構當然需要在未來確定。然而，如果政府後來扣留這些財富，僅分配財富就可以證明轉瞬即逝。一種更持久、更長期的方法也是分配權力：各州可以為每個人配備一個與計算的一部分綁定的唯一密鑰，該公民可以單獨啟動或出租給其他人。這種安排將賦予他們在經濟中的槓桿作用，類似於

勞動者目前有權扣留他們的工作，從而緩和即將到來的自動化浪潮可能產生的財富和權力的集中。

AI 競爭力需要擴大無人機製造，建立使 AI 代理與人類問責制相聯繫的法律框架，並堅定不移地認識到自動化如何擾亂勞動力市場。最重要的是，對臺灣先進人工智慧晶元的依賴是一個關鍵的漏洞。封鎖或入侵可能意味著西方在 AI 方面的優勢結束。為了減輕這種可預見的風險，西方國家應該為 AI 晶片建立有保障的供應鏈。儘管這需要大量投資，但對於國家競爭力來說可能是必要的。

結論

一些觀察家採取了一種厄運的觀點，認為人工智慧的災難已成定局。其他人則預設為鴛鴦的立場，迴避棘手問題，希望事件能夠自行解決。在核時代，宿命論和否認都沒有提供一條合理的前進道路。AI 需要冷靜的關注和具有風險意識的方法：結果，無論是有利的還是災難性的，都取決於我們下一步做什麼。

具有風險意識的戰略是解決威懾、不擴散和戰略競爭等棘手問題的戰略。人工智慧的威懾採取了相互保證的人工智慧故障（MAIM）的形式，即今天 MAD 的對應物，任何追求戰略性權力壟斷的國家都可能遭到競爭對手的報復性回應。為了保持這種威懾力並限制意圖，各國可以擴大其網路攻擊武器庫，以禁用具有威脅性的人工智慧專案。這將重點從“贏得比賽到超級智慧”轉移。接下來，不擴散，讓人想起遏制對裂變材料的獲取，旨在通過限制具有高級病毒學或網路攻擊能力的 AI 晶片和開放重量模型來限制流氓行為者的能力。戰略競爭與冷戰的遏制戰略相呼應，將大國競爭引導到增強實力和彈性上，包括通過國內人工智慧晶片製造。這些措施不會停止，而是穩定了進展。

以實用主義而不是宿命論或否認主義行事的國家可能會發現自己成為財富激增的受益者。隨著人工智慧在無數領域中傳播，社會可以提高生活水平，個人可以以他們認為合適的方式改善自己的福祉。與此同時，人工智慧的經濟紅利豐富了領導者，他們看到了從經濟相互依存中獲得更多好處，緩和精神可能會生根發芽。在經濟增長和緩和時期，緩慢的、多邊監督的情報遞歸——以低風險容忍度和協商的利益分享為標誌——可以慢慢發展超級智慧並進一步提高人類福祉。通過有條不紊地限制最不穩定的舉措，各國可以引導 AI 獲得前所未有的好處，而不是冒著成為毀滅催化劑的風險。

確認

我們要特別感謝 Adam Khoja 密切參與本文的創建。我們還要感謝 Suryansh Mehta 對分析和起草過程的貢獻。我們要感謝 Corin Katze、Daniel King 和 Laura Hiscott 為草案做出的貢獻。我們還要感謝伊斯卡德·雷曼、吉姆·辛恩、馬克斯·泰格馬克、安德魯·克裡奇、賈恩·塔林、內森·拉本斯、艾丹·奧加拉、納撒尼爾·李、理查·任、威爾·霍奇金斯、阿維塔爾·莫裡斯、約書亞·克萊默、隆潘和塔寧·杜尼亞佩拉迪特。

書目

- [1] AI 安全中心。關於 AI 風險的聲明（“減輕 AI 滅絕的風險應成為全球優先事項，同時應對大流行病和核戰爭等其他社會規模的風險。2023。網址：<https://aistatement.com>。

[2]元 AI。機器學習的主要趨勢和數據。訪問時間：2025年2月5日。2023。網址：
<https://epoch.ai/trends>。[3]赫爾曼·卡恩。關於熱核戰爭。新澤西州普林斯頓：普林斯頓大學出版社，
1960年，第668頁。國際標準書號：978-0-691-

02343-1.[4]Horst W. J. Rittel 和 Melvin M. Webber.“規劃通論中的困境”。在：政策科學 4.2

(1973年)，第155-169頁。[5]格雷厄姆·艾利森。註定要戰：美國和中國能否逃脫修昔底德的陷阱？霍頓·
米夫林·哈考特。

2017.[6]Jim Mitre 和 Joel B. Predde.通用人工智慧的五個難題。加利福尼亞州聖莫尼卡：蘭德公司，2025年。
DOI：10.7249/PEA3691-4。[7]愛德華·蓋斯特。戰爭迷霧機器”。載於：不確定性下的威脅：人工智慧和核戰
爭。牛津大學出版社，2023年8月。國際標準書號：9780192886323。DOI：
10.1093/oso/9780192886323.003.0006。電子列印：HTTPs：//學術.哎呀.com/書/0/章/416162987/
章-pdf/52630257/oso-9780192886323-章6.pdf。網址：
<https://doi.org/10.1093/oso/9780192886323.003.0006>。[8]Jr. 帕金斯·雷。“伯特蘭·羅素和預防性戰爭”。收錄
於：伯特蘭·羅素檔案雜誌 14 (1995)，第135-153頁。[9]威廉·伯爾 (William Burr) 和傑弗里·里切爾森
(Jeffrey T. Richelson)。“是否扼殺搖籃中的嬰兒：美國和中國的核計劃，1960-64年”。載於：《國際安全》
第25.3卷 (2000年)，第54-99頁。[10]詹姆斯 D. 費倫。“對戰爭的理性主義解釋”。載於：《國際組織》第
49.3卷 (1995年)，第379-414頁。[11]Jasper Gotting 等人，「病毒學能力測試 (VCT)：多模式病毒學
Q&A 基準」。在：(2025年)。[12]Katarzyna P. Adamala et al. “面對鏡子生活的風險”。收錄於：科學
386.6728 (2024)，第1351-1353頁。[13]美國國土安全部。安全可靠地部署 AI inCritical 基礎設施的開創性
框架。訪問時間：2024年12月6日。2024年11月。網址：[https://www.dhs.gov/news/2024/11/14/開創性-
框架-安全-和可靠-部署-人工智慧-關鍵-基礎設施](https://www.dhs.gov/news/2024/11/14/開創性-框架-安全-和可靠-部署-人工智慧-關鍵-基礎設施)。[14]Dan Hendrycks 等人，ML 安全中未解決的問
題。2022. arXiv：2109.13916 [cs.LG]。網址：<https://arxiv.org/abs/2109.13916>。[15]史蒂夫·紐曼。網路安全
和 AI：不斷發展的安全形勢。訪問時間：2024年12月6日。2024。網址：HTTPs：//www.安全. AI / 博
客 / 網路安全 - 以及 - AI - 不斷發展的安全環境。[16]丹·亨德里克斯。自然選擇偏愛 AI 而不是人類”。在：
ArXiv abs/2303.16200 (2023)。[17]拉菲·哈查杜里安。“世界末日發明”。載於：《紐約客》(2015年11月
23日)。[18]理查·但澤。技術輪盤賭：隨著許多軍隊追求技術優勢，管理失控。技術代表新美國安全中心，
2018年6月。[19]Akash R. Wasil 等人。國際 AI 協定的驗證方法。2024. arXiv：2408.16074。[20]2024 年向
國會提交的報告：執行摘要和建議。美中經濟與安全審查委員會，2024年11月。網址：
https://www.uscc.gov/sites/default/files/2024-11/2024_Executive_Summary.pdf。[21]Andrew J. Coe 和 Jane
Vaynman。“為什麼軍備控制如此罕見”。載於：美國政治學評論 114.2 (2020)，第342-355頁。DOI：
10.1017/S000305541900073X.[22]Aaron Scher 和 Lisa Thiergart。驗證有關 AI 開發的國際協議的機制。技術
代表機器智慧研究所，2024.[23]Richard 任 et al. 安全清洗：AI 安全基準真的衡量安全進展嗎？2024. arXiv：

2407.21792 [CS.LG]。網址：<https://arxiv.org/abs/2407.21792>。[24]Yangjun Ruan、Chris J. Maddison 和
Tatsunori Hashimoto。觀察縮放定律和語言模型性能的可預測性。2024. arXiv：2405.10938 [cs.LG]。網址：
[https://arxiv.org/abs/](https://arxiv.org/abs/2405.10938)

2405.10938.

[25]文森特·富尼耶。“24/7 全天候調查受保護的材料”。載於：國際原子能機構（2016 年）。網址：<https://www.iaea.org/newscenter/news/surveying-safeguarded-material-24/7>。[26]Gabriel Kulp et al. 硬體支援的治理機制：開發技術解決方案以豁免

其他歸類為出口管制分類編號 3A090 和 4A090 的物品。技術代表 RAND Corporation，2024 年。[27]馬克·安德森。白丸 37。晰。訪問時間：2024 年 12 月 6 日。2024 年 1 月。網址：<https://x.com/pmarca/>

status/1747534187597586615 中。

[28]世界人工智慧大會。AI 繼承。<https://www.優酷.com/> 觀看?v=NgHFMolXs3U。2023。

[29]Sella Nevo et al. 保護 AI 模型權重：防止盜竊和濫用 Frontier 模型。加利福尼亞州聖莫尼卡：

蘭德公司，2024 年。DOI：10.7249/RRA2849-1。[30]Minank Sharma et al. 憲法分類器：抵禦數千次普遍越獄

數小時的紅隊合作。2025。arXiv：2501.18837 [cs。網址：<https://arxiv.org/abs/2501.18837>。

[31]Andy Zou et al. 使用斷路器提高對齊和穩健性。2024。arXiv：2406.04313 [cs.LG]。網址：<https://arxiv.org/abs/2406.04313>。[32]莎拉·愛默生。“這個駭客團隊正在為 OpenAI 等公司提供防彈 AI 模型”。在：福布斯（10 月。

2024）。訪問時間：2024 年 12 月 6 日。網址：

<https://www.forbes.com/sites/sarahemerson/2024/10/29/this-hacker-team-is-bulletproofing-ai-models-for-companies-like-openai/>。[33]凱文·羅斯。“與 Bing 聊天機器人的對話讓我深感不安”。引自：紐約時報

（2023 年 2 月 16 日）。網址：<https://www.nytimes.com/2023/02/16/technology/bing-chatbot-microsoft-chatgpt.html>。[34]Mantas Mazeika 等人，“效用工程：分析和控制 AI 中的新興價值系統”。在：

(2025)。[35]Long Ouyang et al. “訓練語言模型以遵循人類反饋的指令”。在：ArXiv（2022）。[36]Yushi Bai et al. “通過從人類反饋中強化學習來訓練一個有用且無害的助手”。

在：ArXiv（2022）。[37]Yuntao Bai 等人。憲法 AI：AI 反饋的無害性。2022。arXiv：2212.08073 [cs.CL]。網址：

<https://arxiv.org/abs/2212.08073>。

[38]Stephen Casper et al. Open Problems and Fundamental Limitations of Reinforcement Learning from Human Feedback。2023。arXiv：2307.15217 [cs.AI]。網址：<https://arxiv.org/abs/2307.15217>。[39]Andy Zou et al. 表示工程：AI 透明度的自上而下的方法。2023。arXiv：2310。

01405。

[40]邁克爾·霍洛維茨。軍事力量的擴散：國際政治的原因和後果。普林斯頓大學出版社，2010 年。[41]Stacie Pettyjohn 等人。海峽上空的蜂擁而至：未來保衛台灣的無人機戰爭。Center for a

新美國安全（CNAS），2024 年 6 月。[42]Daniel M. Gerstein 和 Erin N. Leidy。新興技術和風險分析：無人機系統

智慧 Swarm 技術。加利福尼亞州聖莫尼卡：蘭德公司，2024 年。DOI：10.7249/RRA2380-1。[43]丹·亨德里克斯、曼塔斯·馬澤卡 and 湯瑪斯·伍德賽德。災難性 AI 風險概述。2023。arXiv：

2306.12001 [cs.CY]。

[44]利亞姆·沃恩。Flash Crash：交易專家、全球追捕和歷史上最神秘的市場崩盤。紐約：Doubleday，2020 年。國際標準書號：978-0385543651。[45]路透社。“中國設立了第三隻基金，規模為 475 億美元，以提振半導體行業”。收錄於：路透社（2024）。[46]凱薩琳·艾肯、詹姆斯·鄧納姆和雷姆科·茲韋茨洛特。AI 人才的移民途徑和計劃。中心

安全與新興技術，2020 年。[47]Andy Zou et al. 用神經網路預測未來世界事件。2022。arXiv：2206.15474 [cs.LG]。

[48]Benjamin F. Jones 和 Xiaojie Liu。具有資本體現技術變革的經濟增長框架。工作論文 30459。國家經濟研究局。2022年。[49]Philip Zelikow et al. 防禦 AI 黑魔法：威脅評估和聯盟防禦。技術代表

胡佛研究所。2024 年 12 月。[50]埃裡克·鐘斯（Erik Jones）、安卡·德拉甘（Anca Dragan）和雅各·斯坦哈特（Jacob Steinhardt）。攻擊者可能會濫用安全模型的組合。2024。

arXiv：2406.14595 [cs.CR]。網址：<https://arxiv.org/abs/2406.14595>。[51]利奧波德·阿申布倫納。“態勢感知：未來十年”。在：（2024 年 6 月）。網址：HTTPs：//

situational-awareness.ai/。

[52] Eliezer Yudkowsky 和 Richard Ngo。“Ngo 和 Yudkowsky 關於科學推理和關鍵行為”。在：（2022 年 3 月）。網址：HTTPs：//intelligence.組織/2022/03/01/非政府組織-和-Yudkowsky-關於-科學推理和關鍵行為/。

附錄

答 1 常見問題解答

1. 什麼是調整后利潤？許多人以許多不同的方式使用「加速後投資指數」一詞，這可能會導致在討論風險和政策時產生混淆。我們發現專注於特定功能更有效率，因為這些能力為進度和風險提供了更清晰的指標。智慧前沿是鋸齒狀的——AI 系統可能在某些任務中表現出色，而在其他任務上表現不佳，而且通常以令人困惑的方式出現。例如，2024 年的 AI 模型可以解決複雜的物理問題，但無法可靠地計算「strawberry」等單詞中「r」的數量。這種不平衡的發展意味著 AI 可能會在掌握摺疊衣服等基本體力任務之前自動化經濟的很大一部分，或者在學習駕駛之前掌握微積分。因為這些能力不會同時出現，所以我們沒有明確的終點線來“實現 AGI”。相反，我們應該關注導致嚴重風險的特定高風險能力。三個關鍵功能值得特別關注：

- 高度複雜的網路攻擊能力。
- 專家級病毒學能力。
- 完全自主的 AI 研發能力。

政策決策應取決於人工智慧系統在這些關鍵領域的進步，而不是它們是否跨越了 AGI 的未指定閾值。雖然 AGI 這個術語不是很有用，但超級智慧這個術語代表了在幾乎所有任務中都比人類能力強得多的系統。這樣的系統可能會通過智慧遞迴出現。其他目標，例如 AGI，則更加模糊且不太有用——AI 系統可能是國家安全問題，但仍然不符合“AGI”的條件，因為它們不能摺疊衣服或駕駛汽車。

2. 應該做些什麼來防止人工智慧輔助的恐怖主義？防止 AI 協助的恐怖主義需要多層次的防禦策略。當 AI 系統仍處於 API 等受控介面之後時，一些保護措施可以顯著降低風險。這些包括：

- 瞭解您的客戶（KYC）協定，在授予對潛在災難性雙重用途功能的訪問許可權之前驗證使用者的身份和合法的研究需求。例如，在生物技術領域，需要訪問危險材料的人會尋求適當的授權。在實踐中，相關的企業客戶可以獲得這些兩用生物學能力，而未經審查的消費者則不會。此類政策可以獲得科學利益，同時降低惡意使用風險。
- 輸入和輸出過濾，掃描使用者請求和 AI 回應以阻止與武器化相關的內容。這些過濾器表現出了強大的彈性，一些系統抵擋了數千次嘗試的規避。
- 斷路器 [31]，當它們檢測到與武器化主題相關的處理時，它們會自動中斷 AI 作。這些充當 AI 權重中的嵌入式安全機制。
- 持續監控，跟蹤用戶行為模式以識別和回應惡意活動。

然而，如果 AI 具有潛在的災難性雙重用途，那麼 AI 模型權重（決定 AI 系統能力的核心資訊）的不受控制地釋放將構成嚴重的擴散風險

能力。一旦這些權重公開可用，包括恐怖分子在內的敵對行為者就可以不可逆轉地訪問它們。這與發佈詳細的生物武器食譜將如何造成永久性風險相似。

3. 我們應該如何處理開放重量級 AI？AI 模型權重的發佈提供了明顯的好處，甚至可以推進 AI 安全研究。然而，隨著 AI 系統的能力越來越強，關於釋放權重的決策必須以嚴格的成本效益分析為指導，而不是以權重應始終公開的意識形態承諾為指導。這些決定需要仔細評估，因為體重釋放是不可逆的——一旦發佈，它們將永久可用。開放權重模型最終會帶來幾個重大風險。首先，它們可以根據危險數據進行微調——例如，使用病毒學出版物為生物武器開發創建更有效的工具。其次，安全措施和護欄在發佈后可以很容易地拆除。第三，與封閉的 API 不同，開放模型很難監控濫用，公司可以跟蹤和評估新出現的威脅。第四，它們會產生能力懸而未決，即發佈后的改進顯著增強了系統的能力，超出了初始安全性評估期間的明顯水準[49,50]。當模型跨越關鍵能力閾值時，這些風險變得尤為嚴重。例如，如果人工智慧系統獲得了專家級的病毒學能力，它的公開發佈可以使不熟練的流氓行為者能夠設計災難性的生物武器。鑒於這些複雜的風險，釋放能夠製造大規模殺傷性武器的 AI 模型的權重是不負責任的。利害關係要求對懷疑具有此類功能的模型進行徹底的發佈前測試和獨立風險評估，而不是預先承諾不顧風險發佈 open-weight 模型。

4. 我們應該怎麼做才能在 AI 中嵌入道德？我們不需要將道德嵌入 AI 中。在部署 AI 系統之前“解決”道德是不切實際的，而且道德往往模稜兩可、不完整，不足以指導行動。相反，我們可以遵循植根於既定法律原則的非務實方法，施加類似於依法支配人類行為的基本約束。

- 採取合理的謹慎措施，避免可能預見導致法律相關傷害的行為，例如違反侵權行為或刑事法規。
- 不要明確不誠實，避免說出公開的謊言。
- 堅持對委託人的信託義務，反映職業關係中固有的責任，例如讓委託人合理地了解情況，避免自我交易，保持忠誠。

通過為 AI 系統設定明確的目標並將它們與基本法律義務綁定，我們可以確保它們運行良好而不會造成傷害，而無需解決長期存在的道德難題。

5. 我們應該怎麼做「解決對齊問題」？通過快速自動化 AI 研究開發來引導 AI 系統群體的挑戰與控制單個 AI 系統有著根本的不同。雖然研究人員在控制單個 AI 系統方面取得了進展，但安全管理系統功能越來越強的全自動遞歸過程是一項更複雜的挑戰。它代表了一個棘手的问题——需求很難完全定義，對解決方案的每次嘗試都會改變問題的性質，並且在實施之前沒有明確的方法來完全測試緩解措施的效果。在智慧遞歸期間，AI 功能可能會超過遞歸的保護措施；防止這種情況需要有意義的人工檢查，這將大大減慢遞歸的速度。

在短期內，地緣政治事件可能會阻止情報遞歸的嘗試。展望未來，如果人類選擇嘗試智慧遞歸，它應該在一個有廣泛準備和監督的受控環境中進行，而不是在導致高風險承受能力的極端競爭壓力下進行。

6. 本文是否主張攻擊或轟炸其他國家的人工智慧設施？不。本文將相互保證人工智慧故障（MAIM）描述為一種可能很快存在於大國之間的威懾動態，類似於核威懾。正如冷戰期間討論相互確保毀滅（MAD）並不是宣導核戰爭，而是分析核大國之間形成的戰略動態一樣，本文分析了圍繞破壞穩定的 AI 專案即將到來的戰略格局。MAD 的前提是一個違反直覺的想法，即核武力的相互威脅可能會阻止升級。我們同樣討論了 AI 專案對破壞的脆弱性如何促進避免衝突的威懾動態。AI 分析師此前曾積極呼籲通過超級智慧奪取戰略壟斷[51]，或者讓潛在的非國家行為體使用先進的 AI 單方面做一些“融化所有 GPU”的事情，以防止在“關鍵行為”中失去對超級智慧的控制 [52]。相比之下，本文探討了國家已經擁有的能力（例如網路攻擊）和激勵措施，以威脅穩定的 AI 專案，並提出了從這種動態中建立穩定威懾機制的方法。如果維護得當，MAIM 既可以阻止破壞穩定的 AI 專案，也可以防止升級。

7. 我們如何防止控制權的侵蝕？首先，AI 系統必須保持在人類的直接控制之下，它們不應該是獨立於人類作業的自主實體。這建立了一條明確的界限，即 AI 系統是由人類而不是獨立行為者控制的工具。這種控制需要通過明確的信託義務來變得有意義。與專業顧問一樣，AI 系統應該表現出對人類利益的忠誠，保持其行為的透明度，並在重要決策中獲得知情同意。這確保了人類對 AI 系統擁有真正的權威，而不僅僅是名義上的控制權。使這種控制特別謹慎的一種方法是為具有高級預測功能的人類提供支援。這種支援將說明運營商瞭解 AI 決策的長期影響，更好地實現人工控制和知情同意。這可以防止存在技術人工控制但由於對複雜後果的預見有限而導致不良結果的情況。雖然提高自動化程度自然會減少人類對特定決策的直接控制，但這些措施（確保 AI 系統保持在人類權威之下，通過設立信託義務確保控制有意義，以及實現審慎的決策預測）有助於防止對關鍵決策的控制受到侵蝕，從而導致無能為力。

8. 我們應該如何看待 AI 意識和 AI 權利？我們應該等待解決 AI 意識和權利的問題。這個問題對國家安全並不緊迫，在可預見的未來，我們無法確定任何 AI 系統是否真的有意識。根據投機標準授予 AI 權利可能會產生深遠且不可逆轉的後果。向 AI 系統授予許可權可能會造成 AI 種群的爆炸性增長，例如創建一個呈指數級增長的新國家，人口迅速超過人類。自然選擇會偏愛 AI 而不是人類 [16]，允許這種無節制的生長可能會從根本上威脅人類安全。與有意識的 AI 系統共存的道路仍不明朗。雖然潛在的好處尚不清楚，但行動太快可能會對人類造成嚴重後果。謹慎的做法是將這個問題推遲到我們形成更清晰的理解之前。

9. 讓 AI 更安全不是讓它更有能力嗎？

隨著 AI 系統變得更強大，一些安全特性確實會自然而然地提高。隨著模型變得更好，它們犯的基本錯誤更少，並且變得更加可靠。例如，像 TruthfulQA 和常識測試這樣的誤解基準與計算高度相關，這表明功能更強大的模型自然更擅長避免常見的事實錯誤。但是，許多關鍵的安全特性並不能僅僅通過使 AI 系統更智慧來改善 [23]。

- 對抗性魯棒性（抵禦複雜攻擊的能力）不會隨著可用的標準 AI 模型變得更強大而自動修復。
- 就像人類一樣，道德行為不受智力的保證。默認情況下，更有能力的模型不會做出越來越符合我們的道德信念的決定。控制他們的價值體系需要額外的措施。
- 隨著某些軍民兩用能力的增加，一些風險會變得更糟。例如，功能更強大的模型顯示出在生物安全和網路安全等領域惡意使用的可能性增加。他們在這些領域的知識和能力隨著他們的一般能力而增長。

雖然基本可靠性會隨著功能的增加而提高，但許多關鍵的安全挑戰需要專門的研究和特定的保護措施，而不僅僅是使模型更強大。安全研究人員應關注不會自然而然地脫離一般上游能力的安全特性。

答 2 指標

超級大國的約束意圖（威懾）

MAIM：可能使主要 AI 項目癱瘓的關鍵零日數

約束 Rogue Actor 的功能（nonproliferation）

計算安全性：位置未知的高端 AI 晶片數量

jailbreaks：越獄前的嘗試次數；是時候檢測紅隊成員濫用 API（KYC）了

兩用能力：試驗表明沙盒業餘愛好者是否可以製造強大的生物或網路武器

Intelligence Recursion：用於保護升級的計算分數；全能殺戮風險承受能力

提高對其他狀態的相對實力（競爭力）

經濟實力：國內製造的高端人工智慧晶元百分比；AI 佔 GDP 的百分比